UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Scuola di Economia e Statistica

Corso di laurea in

SCIENZE STATISTICHE ED ECONOMICHE

RELAZIONE TRA CO_2 E LIVELLO DEL MARE: UN'ANALISI ATTRAVERSO MODELLI DI SERIE STORICHE

Relatore: Andrea Marletta

Tesi di Laurea di:

Lorenzo Triolo

Matr. N. 895541

Anno Accademico 2024/25

Indice

Introduzione ..... **iii**
1. Contesto scientifico e stato dell'arte **1**
1.1 Introduzione: Contesto climatico 1
1.2 Statistica Ambientale ed ambiti applicativi 2
1.2.1 L'approccio metodologico della statistica ambientale nella presente tesi 5
1.3 Rassegna della letteratura 5
1.3.1 L'inizio di una presa di coscienza (Anni '80 - '90) 5
1.3.2 Studio del livello marino e proiezioni complesse (2000 - 2015) 7
1.3.3 Modernizzazione delle proiezioni e modelli probabilistici (2015 - oggi) 10
1.4 Conclusione ed obiettivi 13
2. Metodologie di Analisi e Modellazione delle Serie Storiche **14**
2.1 Introduzione al capitolo 14
2.2 Serie Storiche e proprietà 14
2.3 Procedura di Box - Jenkins 16
2.3.1 Modelli Autoregressivi e a Media mobile 17
2.3.2 Modelli Misti, Integrati e Stagionali 18
2.3.3 Stima di parametri e criteri di scelta 21
2.3.4 Diagnostica dei residui 22
2.3.5 Previsione 23
2.4 Serie Multivariate, Causalità e VAR 24
2.5 Cointegrazione e VECM 26
2.6 ARDL 29
2.7 Conclusione 30
3. Dati e Preprocessing **31**
3.1: Introduzione al Capitolo: Scopo e metodi 31
3.2: Descrizione dei Dataset e Preprocessing 31
3.3 EDA 34
3.3.1 Visualizzazione delle serie originali individualmente e congiuntamente 34
3.3.2 Analisi della stazionarietà e della stagionalità della concentrazione di CO2 36
3.3.3 Analisi della stazionarietà e della stagionalità della concentrazione di GMSL 39
3.4 Decomposizione delle serie storiche e analisi delle componenti classiche 42
3.4.1 Decomposizione della CO2 42
3.4.2 Decomposizione del GMSL 43
4. Modellizzazione e Previsione **45**
4.1 Introduzione ed Obiettivi 45
4.2 Modellizzazione della Serie della concentrazione di CO2 46
4.3 Modellizzazione della serie del GMSL 50
4.4 Analisi Multivariata: Causalità e VAR 55

4.5 Analisi Multivariata: Cointegrazione e ECM..... 58
4.6 Analisi Multivariata: ARDL..... 60
4.7 Conclusione e discussione dei risultati..... 61
Conclusione e sviluppi futuri..... **63**
Bibliografia..... **65**

Introduzione

Il cambiamento climatico rappresenta una delle sfide più urgenti e complesse del XXI secolo, con conseguenze che non si riflettono solamente sugli equilibri naturali ed ambientali, ma che risultano essere di forte impatto anche sugli aspetti sociali ed economici della vita umana di tutti i giorni. Tra i molteplici fenomeni associati al cambiamento climatico ed al riscaldamento globale, l'aumento della concentrazione di anidride carbonica e l'innalzamento del livello medio del mare costituiscono due indicatori centrali e per questa ragione sono costantemente monitorati da scienziati ed esperti. Comprenderne le dinamiche e la relazione reciproca è un passaggio cruciale per poter valutare gli scenari futuri.

Negli ultimi decenni sono stati sviluppati diversi approcci per lo studio di questi fenomeni: dai modelli fisici, capaci di simulare le dinamiche ambientali più complesse, fino a metodi numerici e probabilistici, che combinano scenari emissivi differenti valutandone le possibili conseguenze.

Il percorso seguito in questa tesi si avvicina a quest'ultimo filone, adottando una prospettiva quantitativa fondata sull'analisi delle serie storiche per indagare, attraverso l'applicazione di modelli univariati e multivariati, il legame tra le emissioni di CO_2 e l'innalzamento del livello medio globale del mare (Global Mean Sea Level, GMSL).

L'obiettivo finale è quello di fornire proiezioni aggiornate e interpretazioni empiriche solide. A tal fine, è stata applicata la procedura di Box-Jenkins (SARIMA) per la modellizzazione univariata, mentre per la dimensione multivariata sono stati implementati modelli quali VAR, ECM e ARDL.

La struttura del lavoro è organizzata in più capitoli, ciascuno con un ruolo specifico nel percorso di analisi:

- Nel primo capitolo viene presentato il contesto scientifico entro cui si inserisce la ricerca. Dopo un'introduzione agli effetti del cambiamento climatico e al ruolo centrale delle emissioni di CO_2, viene offerta una rassegna della letteratura internazionale sul legame tra concentrazioni atmosferiche e innalzamento del livello del mare. Qui viene inquadrato il problema, evidenziando sia le principali evidenze empiriche raccolte, sia la varietà di approcci modellistici sviluppati.
- Il secondo capitolo è dedicato alla parte metodologica. In esso vengono presentate le nozioni fondamentali relative all'analisi univariata delle serie storiche, ed in

particolare alla procedura di Box-Jenkins e ai modelli ARIMA e SARIMA. Viene inoltre introdotta l'analisi multivariata, con una descrizione dei principali modelli utilizzati (VAR, ECM e ARDL), che costituiscono la base per lo studio della relazione dinamica tra le variabili.

- Nel terzo capitolo si passa alla fase empirica, con la descrizione dei dataset utilizzati e delle operazioni di preprocessing effettuate. Viene inoltre condotta un'analisi esplorativa preliminare, utile a comprendere le caratteristiche fondamentali delle serie e a verificare proprietà come la stazionarietà e la stagionalità. Questa sezione ha lo scopo di preparare i dati per la modellizzazione successiva.
- Il quarto capitolo presenta la fase di modellizzazione vera e propria. Dopo aver stimato e validato i modelli univariati e multivariati, vengono presentate le previsioni ottenute, mettendole a confronto con quanto emerge dalla letteratura.
- Infine, nelle conclusioni, vengono riassunti i principali contributi emersi dal lavoro e vengono delineati alcuni possibili sviluppi futuri, con l'obiettivo di suggerire nuove prospettive di ricerca che possano arricchire e approfondire ulteriormente i risultati ottenuti.

CAPITOLO 1 – Contesto scientifico e stato dell'arte

1.1 Introduzione: Contesto climatico

Nel corso degli ultimi decenni gli effetti dovuti al cambiamento climatico sono stati sempre più evidenti e hanno attirato in maniera crescente l'attenzione dell'opinione pubblica e degli esperti, costituendo una delle maggiori sfide del XXI secolo. Le conseguenze di questi cambiamenti - come lo scioglimento dei ghiacciai e l'innalzamento del livello dei mari - sono ormai sempre più tangibili nella quotidianità di gran parte della popolazione mondiale e questo ha aumentato la consapevolezza degli organi di governo verso un tema da sempre molto dibattuto. La maggior parte di questi dibattiti sono presieduti dall'IPCC (Intergovernmental Panel Climate Change), un organismo internazionale adibito al controllo ed alla valutazione dei cambiamenti climatici, istituito dall'OMM (Organizzazione Meteorologica Mondiale) e dal Programma delle Nazioni Unite per l'Ambiente (UNEP).

È proprio a partire dalle evidenze raccolte da organismi come l'IPCC che è sorta la necessità di organizzare vertici internazionali tra i capi di Stato e delle delegazioni scientifiche con cadenza annuale: la Conferenza delle Parti (COP). Tra le 29 ad essersi svolte fino al momento della stesura di questa tesi (2025), una delle più rilevanti è sicuramente quella svoltasi a Kyoto nel 1997, che ha portato all'adozione del Protocollo di Kyoto, il primo ad imporre vincoli sulle emissioni di gas serra. Un'altra conferenza degna di nota è stata la COP 21 a Parigi nel 2015, anno dell'Accordo di Parigi in cui la maggior parte degli Stati ha affermato di impegnarsi a contenere l'aumento della temperatura globale a 1.5°C rispetto ai livelli preindustriali.

L'IPCC non conduce ricerche proprie ma valuta e sintetizza le pubblicazioni scientifiche sul clima all'interno dei suoi Assessment Report (Rapporti di Valutazione), pubblicati circa ogni sei anni e strutturati in tre volumi (uno per ciascun gruppo di lavoro: analisi fisico-scientifica, analisi degli impatti e possibili soluzioni) a cui ne segue poi uno di sintesi (Synthesis Report).

L'ultimo rapporto di valutazione ad essere stato redatto è stato il sesto (AR6), pubblicato tra il 2021 ed il 2023. Questo report sottolinea al suo interno l'urgenza e la necessità di intervenire per ridurre le emissioni di gas serra, in modo da limitare l'aumento della temperatura globale ad 1.5 °C entro il 2030 (IPCC AR6, 2023).

Nell'AR6 sono elencate anche le conseguenze del riscaldamento globale, che nel 2021 aveva raggiunto un aumento di 1.1 °C rispetto ai livelli preindustriali. Tra queste c'è sicuramente l'intensificarsi di fenomeni estremi come siccità, ondate di calore ed alluvioni che stanno

colpendo tutto il pianeta, ma maggiormente le popolazioni più povere e vulnerabili che stanno subendo le conseguenze più gravi di questi cambiamenti nonostante abbiano contribuito di meno alle emissioni.
Il rapporto IPCC AR6 delinea inoltre alcune soluzioni possibili per raggiungere gli obiettivi prefissati in termini di emissioni: transizione energetica, agricoltura sostenibile e modifiche nelle abitudini di consumo.
Per poter affrontare e cercare di arginare l'intensificarsi degli eventi estremi citati in precedenza, è fondamentale analizzare le dinamiche che li alimentano. Tra gli indicatori più strettamente connessi al riscaldamento globale vi sono la concentrazione di CO_2 atmosferica e l'innalzamento del livello del mare, oggetto di indagine di questo elaborato. Comprendere la complessità dei processi che li governano e che son descritti all'interno del rapporto dell'IPCC, richiede l'impiego di strumenti quantitativi di analisi sempre più robusti e precisi, in grado di cogliere eventuali pattern latenti presenti nei dati.

1.2 Statistica Ambientale ed ambiti applicativi

La comprensione e lo studio delle dinamiche legate al cambiamento climatico si fondano su una vasta gamma di fenomeni naturali i cui dati solitamente sono caratterizzati da una distribuzione geografica oppure si presentano sotto forma di serie storiche. Per esempio, tutti i dati sull'andamento delle temperature, delle precipitazioni e dei livelli di particolato nell'aria presentano la struttura tipica di una serie storica, cioè un set di osservazioni raccolte nel tempo.
Ad occuparsi della raccolta, dell'analisi, della modellizzazione e dell'interpretazione dei dati relativi all'ambiente naturale è un ramo particolare della statistica chiamato Statistica Ambientale. Questa disciplina serve a studiare fenomeni ambientali, a valutare l'impatto delle attività umane su ecosistemi e clima e, sulla base di dati storici, a prevedere scenari futuri.
All'interno della letteratura scientifica vi sono molteplici articoli e ricerche che testimoniano l'impiego di analisi quantitative per lo studio di dinamiche ambientali e naturali. Di seguito vengono presentati alcuni esempi di importanti studi svolti mediante l'impiego di alcune metodologie statistiche diverse tra loro e sviluppate nell'ambito della Statistica Ambientale.

Un esempio significativo dell'applicazione della Statistica Ambientale si riscontra nell'articolo "A case for environmental statistics of early life" (Frankenhuis et al., 2019) in cui gli autori introducono il concetto di autocorrelazione e di variabilità nelle serie temporali

per comprendere meglio come i sistemi ambientali si evolvono nel tempo. Lo studio si fonda sul concetto di 'colore del rumore' secondo cui l'autocorrelazione, ovvero quanto i valori ambientali in un dato momento sono correlati con i valori dei momenti precedenti, ha diversi gradi. Alla crescente intensità delle autocorrelazioni è stata associata una scala cromatica che parte da colori chiari fino a toni più scuri e per questo nell'articolo si parla di rumore (correlazione) bianco, rosa, marrone o nero. Inoltre per ciascun grado di autocorrelazione vi è un livello differente di prevedibilità ambientale: più scuro è il colore del rumore e maggiore è la prevedibilità.
Le variabili di cui è stata osservata e quantificata l'autocorrelazione in questo studio sono temperatura, precipitazioni, luce e intensità del vento (o della corrente per gli habitat marini). Son tutte caratteristiche che descrivono le condizioni fisiche e chimiche degli habitat che, come evidenziato nel corso di questo studio, sono maggiormente autocorrelate negli habitat marini rispetto a quelli terrestri.
Le conclusioni di questo studio sono da tenere in considerazione in quanto questo è un aspetto che potrebbe influenzare le strategie adattive degli organismi che popolano questi ecosistemi.

Un'altra importante ricerca nell'ambito della statistica ambientale è quella intitolata "Trend analysis of climate time series: A review of method" (Mudelsee, 2019), in cui viene offerta una revisione delle metodologie statistiche impiegate per l'analisi delle serie storiche climatiche.
Nel suo articolo l'autore parte dal presupposto che generalmente le variabili climatiche siano dei processi stocastici formati da una componente di tendenza ed una di incertezza. Il suo scopo all'interno di questo studio è quello di confrontare diversi metodi di stima e di analisi per riuscire a trovare quello che meglio modellizzi la tendenza e per farlo confronta metodi di regressione parametrica lineare, non lineare ed infine modelli non parametrici.
Dopo aver esaminato diversi approcci, Mudelsee evidenzia come le performance dei modelli parametrici che usano il metodo di stima più semplice (Ordinary Least Squares - OLS) siano penalizzate dal venir meno dei presupposti su cui si fondano: normalità ed incorrelazione dei residui. Per questa ragione, l'autore nel suo articolo suggerisce l'utilizzo di modelli di regressione di lineare con metodi di stima dei parametri come i Weight Least Squares (WLS) o i Generalized Least Squares (GLS) perchè riescono a gestire la correlazione tra i residui ottenendo stime più efficienti, così come il modello non lineare Moving Block Bootstrap (MBB) resampling che non formula assunzioni sui residui.

Un ulteriore esempio dell'applicazione della statistica ambientale lo troviamo nell'articolo "Air temperature time series for King George Island, Antarctica" ad opera di Ferron, Simoes, Aquino, & Setzer (2004). Gli autori presentano in questa pubblicazione un'analisi dettagliata della serie storica della temperatura dell'aria dell'isola di Re Giorgio, situata in Antartide, area di particolare interesse scientifico per la sensibilità ai cambiamenti climatici dal momento che gioca un ruolo cruciale nella dinamica dello scioglimento del ghiaccio marino e del conseguente innalzamento del livello del mare.

Questo studio è riuscito ad evidenziare il trend di crescita della temperatura a causa del riscaldamento globale con un aumento di 1.1°C in 49 anni, oltre alla presenza di variazioni stagionali nei valori della temperatura media e alla presenza di una correlazione negativa tra temperatura ed estensione del ghiaccio marino (Ferron et al., 2004). Per giungere a queste evidenze gli autori si sono serviti di strumenti statistici come il coefficiente di determinazione (R^2), la deviazione standard e la differenza media delle temperature. Inoltre è stata misurata la variazione della temperatura media stagionale negli anni e l'inverno è risultata essere la stagione con l'incremento maggiore. come viene illustrato nella figura 1.1.

Questo studio fornisce un'evidenza diretta del riscaldamento globale in una delle regioni più vulnerabili del pianeta, confermando la correlazione tra l'aumento delle temperature e l'innalzamento del livello del mare.

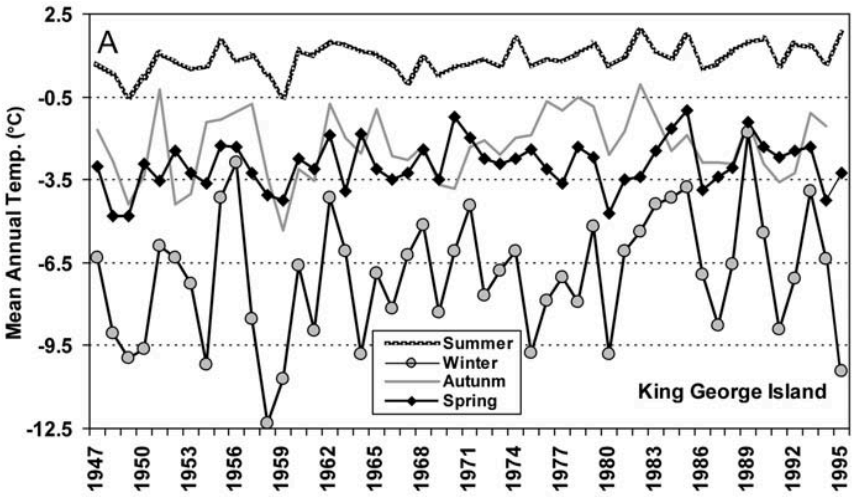

Figura 1.1: andamento della temperatura media per ogni stagione nella King George Island, dati di frequenza annuale. Fonte: Ferron et al. (2004)

1.2.1 L'approccio metodologico della statistica ambientale nella presente tesi

Il presente lavoro si pone come obiettivo l'analisi delle serie storiche delle concentrazioni di CO_2 atmosferica e dell'innalzamento del livello dei mari per una comprensione profonda di questi fenomeni climatici. Per fare ciò, verrà adottato un approccio quantitativo riconducibile alle metodologie della statistica ambientale che si concentrerà su alcuni aspetti in particolare:

- Verifica della stazionarietà e gestione dell'autocorrelazione
- Analisi di correlazione e di causalità tra le due variabili
- Modellizzazione del fenomeno tramite modelli di serie storiche moderni

L'approccio metodologico adottato in questa tesi si baserà dunque sulla combinazione dell'analisi delle proprietà delle serie storiche con metodologie più avanzate per la stima delle tendenze e la previsione. Ciò consentirà di fornire delle evidenze quantitative e scientificamente robuste, necessarie per poi trarre delle conclusioni sul nesso tra le due variabili considerate.

1.3 Rassegna della letteratura

Visti gli obiettivi di questa tesi, che mira ad esplorare le serie storiche di CO_2 e l'innalzamento del livello dei mari, questa sezione offrirà una panoramica della letteratura scientifica preesistente a riguardo. Verranno prese in esame e presentate in ordine cronologico le principali teorie elaborate, i modelli sviluppati ed i risultati empirici ottenuti che sono il risultato della ricerca su questo tema cruciale ed in cui affonda le radici l'analisi che seguirà all'interno di questo elaborato.

1.3.1 L'inizio di una presa di coscienza (Anni '80 - '90)

Lo scienziato Roger Revelle, con il suo articolo "Carbon Dioxide and World Climate" pubblicato nella rivista Scientific American, mira a sensibilizzare la comunità scientifica sulla crescente preoccupazione riguardo la questione ambientale e climatica (Revelle, 1982). Con questo lavoro pionieristico l'autore cerca di presentare lo stato dell'arte dell'epoca in merito all'aumento della CO_2 atmosferica e alle sue ripercussioni sul nostro pianeta, andando contro ad alcune convinzioni dell'epoca (es. l'oceano come serbatoio illimitato).

Revelle nel suo articolo considera due serie storiche sulla concentrazione di CO_2 in due punti diversi del globo terrestre: una rilevata a Mauna Loa e una rilevata al Polo Sud, entrambi considerate dal 1956 al 1980. Le due serie mostrano un andamento crescente e questo allarma l'autore, il quale si dice preoccupato visto anche l'aumento previsto della popolazione globale

ed il conseguente aumento delle emissioni derivanti dall'utilizzo di combustibili fossili. Nell'ultima pagina dell'articolo, viene sottolineato come nei due decenni antecedenti alla pubblicazione dell'articolo, più del 40% delle emissioni di CO_2 siano rimaste nell'atmosfera, non venendo assorbite dagli oceani come si pensava accadesse all'epoca. Inoltre, Revelle mette in guardia sul possibile scioglimento della calotta glaciale artica, che porterebbe ad un aumento notevole del livello del mare nell'arco di un secolo e ad un impatto devastante sulle zone costiere.
Si può dunque concludere che questo articolo, per quanto sia stato scritto più di quarant'anni fa, aveva perfettamente inquadrato un problema che sarebbe poi diventato più attuale che mai, sottolineando la necessità di un cambiamento e di un attento monitoraggio.

Sulla scia della crescente consapevolezza riguardo all'aumento di CO_2 e alle sue potenziali implicazioni sulla società, la ricerca si è successivamente spostata anche verso i fattori demografici che determinano le emissioni. È in questo contesto che si inserisce lo studio di Schmalensee e colleghi, i quali si sono posti due obiettivi: predire le emissioni globali di CO_2 derivanti dalla combustione di combustibili fossili fino al 2050, confrontare le loro proiezioni con quelle dell'IPCC (Schmalensee et al., 1998).
Per creare queste previsioni, gli autori si sono serviti di una base di dati rilevata su un panel a livello nazionale a cui hanno applicato dei modelli econometrici a forma ridotta, ovvero in cui le variabili endogene dipendono solamente dalle variabili esogene e dall'errore. In particolare qui si provano a spiegare le emissioni pro capite di anidride carbonica c_{it} (variabile endogena) in funzione del reddito pro capite y_{it} (esogena) e degli effetti fissi (α_i,β_t)
Questa l'equazione del modello adottato: $ln(c_{it}) = \alpha_i + \beta_t + F[ln(y_{it})] + \varepsilon_{it}$
Nella parte di analisi dell'output del modello, è stata osservata una cosiddetta 'relazione ad U inversa' (figura 1.2) tra le emissioni ed il reddito, con le due variabili che inizialmente hanno lo stesso andamento crescente, finché non viene raggiunto un determinato valore del reddito oltre cui le emissioni cessano di crescere. Per questa ragione i paesi in via di sviluppo mostrano emissioni crescenti con il PIL pro capite, mentre nei paesi sviluppati queste tendono a stabilizzarsi. Questa elasticità variabile del reddito è dovuta alla funzione spline F con cui è stato modellizzato il logaritmo del reddito, che risulta essere flessibile. Una funzione spline serve a modellare delle relazioni non lineari tra variabili e per fare ciò è composta da più tratti di polinomi che si incontrano in dei punti detti "nodi" (De Boor, 2001).

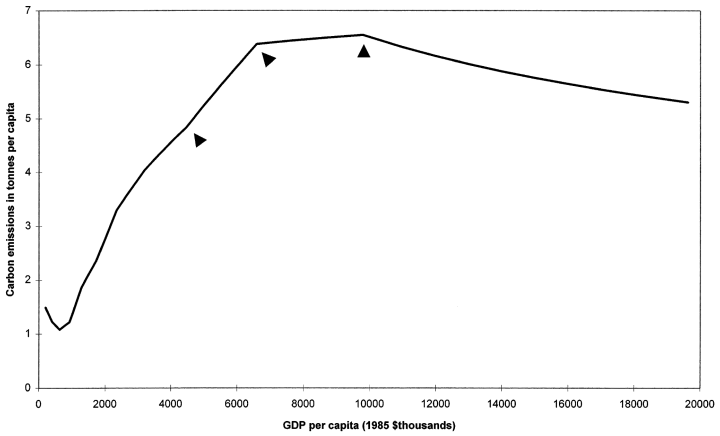

Figura 1.2: grafico in cui a ciascun valore del PIL americano pro capite sono associate emissioni di CO_2 pro capite. Fonte: Schmalensee et al. (1998)

In seguito gli autori vogliono confrontare le proprie proiezioni con quelle dell'IPCC, che erano state definite fin troppo conservative e non rappresentative della realtà (Eckaus, 1994). Per poter fare le loro proiezioni, i tre scienziati han dovuto prendere delle decisioni in merito a due questioni: la gestione dell'elasticità variabile e la gestione degli effetti dovuti al tempo. La prima questione, dopo aver valutato l'idea di adottare un modello semplificato con elasticità sempre positiva, è stata risolta tramite l'accettazione dell'elasticità negativa nel segmento più alto del reddito pro capite. Per quanto riguarda gli effetti temporali, sono stati proiettati usando due valide alternative: prima un modello spline lineare con crescita diversa prima e dopo il 1970 e poi un modello logaritmico. Nonostante entrambi i modelli abbiano performance simili dal punto di vista del R^2, il modello spline presenta un trend che continua in modo costante dopo il 1970, mentre il modello logaritmico prevede un rallentamento progressivo delle emissioni procapite.

Una volta chiariti i presupposti dietro al modello, gli autori di questo studio hanno svolto un confronto tra le proiezioni da loro ottenute e quelle dell'IPCC, che per loro son risultate essere eccessivamente inferiori alle proprie e troppo ottimistiche viste le evidenze storiche. Le cause di un tale scostamento son per loro da ricercarsi nella limitata base di dati dei modelli IPCC e nella conseguente incapacità di cogliere trend storici persistenti.

1.3.2 Studio del livello marino e proiezioni complesse (2000 - 2015)

Tra gli articoli disponibili e pubblicati durante i primi quindici anni degli anni 2000, ne son stati selezionati due in particolare: quello pubblicato da Mimura e quello di Foster & Rohling.

Il primo (Mimura, 2013), intitolato "Sea-level rise caused by climate change and its implications for society", offre un'analisi completa dello stato dell'arte riguardo al livello del

mare, alle sue cause e alle proiezioni, operando un confronto con i rapporti redatti da IPCC nel loro AR4 del 2007.

Nel momento della stesura dell'articolo (2012 - 2013), il livello medio globale del mare era cresciuto di circa 21 cm, con un tasso di crescita leggermente inferiore ai 2 mm all'anno dall'inizio del XX secolo fino alla metà degli anni '90, da cui ha quasi raddoppiato il proprio tasso fino a toccare i 3.5 mm/anno.

Dopo aver sottolineato la differenza nell'innalzamento del livello del mare, Mimura decide di dedicare una sezione della sua rassegna all'indagine delle cause di questo scostamento tra i due livelli. L'autore attribuisce questo cambiamento all'espansione termica dell'acqua marina, allo stoccaggio terrestre e allo scioglimento e quindi alla diminuzione delle superfici delle calotte glaciali, in particolare in Groenlandia (Greenland Ice Sheet - GIS) e nell'Antartide Occidentale (West Antarctic Ice Sheet - WAIS).

Inoltre l'autore sostiene che l'innalzamento non sia geograficamente uniforme, ma che presenti forti variazioni regionali che devono essere tenute in considerazione quando si valutano i rischi legati all'innalzamento del livello del mare, come mostrato nella figura 1.3. Viene mostrato come il livello del mare relativo possa sensibilmente discostarsi da quello totale (Global Mean Sea Level Rise - GMSLR) a causa di correnti oceaniche regionali, movimenti della crosta come la GIA (Glacial Isostatic Adjustment) o anche a causa della subsidenza indotta dall'uomo con un eccessivo prelievo di acque sotterranee.

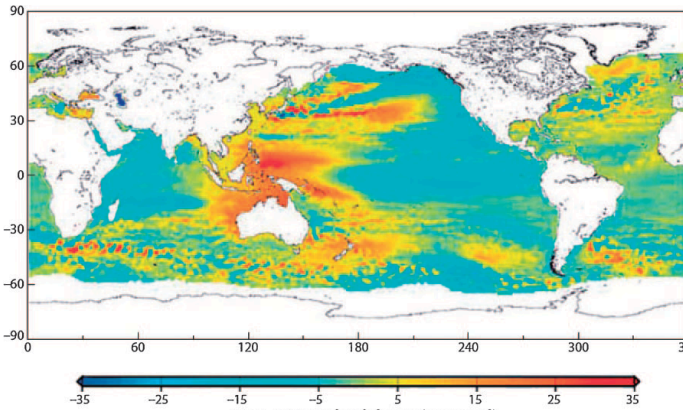

Figura 1.3: variazioni regionali relative del SLR, Fonte: Mimura (2013).

Terminate le considerazioni riguardo alle differenze passate, Mimura si è dedicato ad analizzare le diverse previsioni future fino al 2100 e ha analizzato due tipologie di modello diverse: process-based, usato negli Assessment Report, e semi-empirical, messo a punto da Rahmstorf (2007). Quello usato dall'IPCC per stimare e predire i valori futuri del GMSLR è

un modello climatico fisico che simula meccanicamente e modella le componenti individuali che contribuiscono all'aumento del livello, escludendo però le dinamiche glaciali. Il modello teorizzato da Rahmstorf invece si basa su una relazione empirica tra la temperatura globale media ed il livello di innalzamento del mare osservato in passato, e questo legame viene ritenuto costante. In questo modello vengono inclusi i processi delle calotte glaciali dal momento che considerano dati influenzati al loro interno da queste dinamiche.
Le performance dei due modelli differiscono notevolmente: il modello dell'IPCC AR4 sottostima l'innalzamento, stimando un range tra 26 e 59 cm entro il 2100, mentre il modello semi-empirico ottiene il risultato contrario dal momento che rischia di sovrastimare il reale innalzamento, ponendo un range tra 50 e 140 cm. Mimura sottolinea che questa tipologia di modello empirico manca di un fondamento fisico, che potrebbe portare il modello a non essere più affidabile in uno scenario con temperature più alte, dove determinate dinamiche fisiche non verrebbero considerate nelle previsioni.
Nonostante i limiti dei modelli sopra citati, l'autore afferma che il potenziale rischio di un significativo e improvviso innalzamento del livello del mare non va sottovalutato, soprattutto se si dovesse verificare una disintegrazione accelerata delle calotte glaciali, specialmente di GIS e WAIS.
Mimura conclude la sua rassegna dedicando un'ampia parte del proprio articolo ai rischi ambientali e sociali legati all'aumento estremo del GMSL (Global Mean Sea Level). Tra le principali conseguenze egli individua: l'inondazione e l'erosione delle aree costiere, con un diretto impatto sugli ecosistemi costieri come barriere coralline e mangrovie, oltre all'intrusione di acqua salata nelle falde acquifere e al rischio sociale specialmente in zone vulnerabili come l'Asia e l'Africa.

Il secondo articolo è è intitolato "Relationship between sea level and climate forcing by CO_2 on geological timescales" (Foster & Rohling, 2013). Questo lavoro di ricerca analizza dati su scale temporali comprese tra 10^3 e 10^6 anni e vuole verificare la forza del legame tra le due variabili su scale geologiche. Per ricostruire dati così antichi sono stati usati isotopi di carbonio e analisi stratigrafiche provenienti da cinque fasi degli ultimi 40 milioni di anni di storia. Sono state proprio queste cinque "time slices" geologiche ad essere utilizzate per la costruzione di una curva che collegasse i livelli di CO_2 e di innalzamento del livello del mare. La relazione tra le due variabili è risultata essere fortemente non lineare, ma anzi può essere definita "sigmoidea" con una sensibilità diversa in base ai diversi livelli delle variazioni di CO_2. In questo articolo i due autori sostengono che, viste anche le concentrazioni di anidride

carbonica nelle 5 ere geologiche passate e l'associato innalzamento delle acque marine, è abbastanza improbabile che il GMSL aumenti solo di 2 metri come pronosticato nel peggiore dei casi da altri studiosi in precedenza. Gli autori infatti sostengono che il confronto tra le rilevazioni geologiche passate ed il livello di concentrazione rilevato all'epoca della scrittura, unito all'effetto devastante di un ipotetico scioglimento della calotta polare, possa generare nei secoli un innalzamento del livello del mare di 9 metri e sostengono che ciò possa accadere con un livello di confidenza del 68%.

Gli autori infine affermano di essere consapevoli che il loro modello non funzioni propriamente nel pronosticare il livello del mare entro la fine del secolo, ma sostengono che questo abbia ottime performance nel lungo periodo poiché, basandosi su molteplici ere geologiche precedenti, è addestrato su una vasta gamma di dati ed è in grado di descrivere l'equilibrio che il sistema climatico raggiungerà una volta che si sarà stabilizzata la concentrazione di CO_2, questione di secoli o di millenni addirittura.

Sebbene il modello non sia prettamente performante nei prossimi decenni, il contributo dato da questo studio alla presente tesi è notevole visto che l'approccio adottato dagli autori si fonda su una scala temporale molto vasta e su basi di dati differenti da quelle fin qui considerate, fornendo un'ottica temporalmente più vasta della questione.

1.3.3 Modernizzazione delle proiezioni e modelli probabilistici (2015 - oggi)

In questa ultima sezione di rassegna della letteratura preesistente, utile a fornire una panoramica sullo stato dell'arte della questione climatica, verranno analizzate due ricerche pubblicate negli ultimi dieci anni e che siano in grado di fornire una visione ancora più attuale della questione.

Il primo articolo in questione è quello pubblicato da Hisham A. Maddah dal titolo "Modeling the Relation between Carbon Dioxide Emissions and Sea Level Rise for the Determination of Future (2100) Sea Level" (Maddah, 2016). In questo studio, pubblicato sull'American Journal of Environmental Engineering, l'autore sceglie di indagare le serie storiche GMSL e del livello di CO_2 tramite la comparazione dei livelli medi annuali di entrambe le variabili dal 1994 al 2008. Da parte dell'autore viene riscontrata fin da subito una forte correlazione, come testimonia la figura 1.4.

Inoltre all'interno dello studio vengono tenute in considerazione le variazioni annuali della temperatura e del flusso di calore terrestre (o forzante radiativo), ovvero la differenza tra l'energia in eccesso assorbita dal sole e quella reimmessa nello spazio (Ramaswamy et al. 2001). È proprio sulle diverse quantità di quest'ultima grandezza che si basano i due diversi

scenari futuri predetti dai modelli di Maddah. Nel suo modello empirico, l'autore inserisce le sue previsioni in una cornice costituita da due scenari climatici estremi delineati dall'IPCC AR5, noti come RCP2.6 e RCP 8.5, dove RCP sta per Representative Concentration Pathways e sono profili di forzante radiativo (IPCC, 2014). Il primo corrisponde all'ipotesi più ottimistica, in cui vengono attuate politiche climatiche stringenti, che invertano le tendenze emissive, con un GMSLR pari a 0.2 - 0.4 m. A questo scenario ideale si contrappone quello in cui non avviene mitigazione, in cui le emissioni di gas serra aumentano costantemente e da parte delle istituzioni globali vi è un astensione dall'intervenire. Questo scenario porterebbe il livello del mare ad innalzarsi addirittura fino a 1.6 metri entro il 2100.

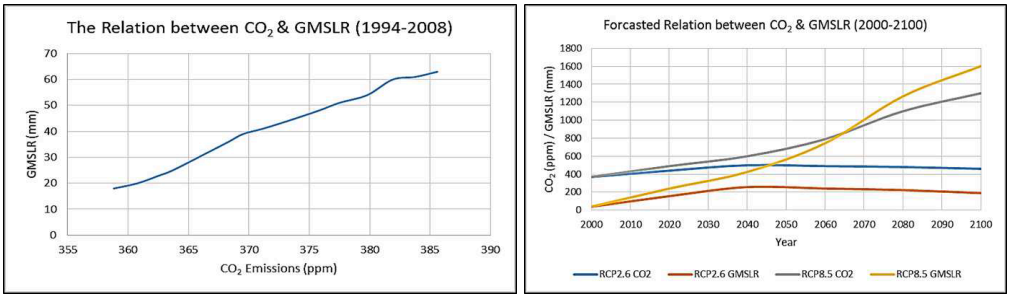

Figura 1.4: relazione lineare tra il livello di CO_2 e GMSLR (sinistra) e valori previsti per le due variabili nei due diversi scenari di RCP. Fonte: Maddah (2016)

Infine l'autore analizza la distribuzione geografica dell'innalzamento relativo, evidenziando quali siano i mari e gli oceani maggiormente colpiti da questo cambiamento e quali quelli meno toccati. Maddah afferma che in entrambi gli scenari di RCP l'oceano ad essere più colpito da questo aumento è il Pacifico e quello meno impattato è il Mar Artico (figura 1.5), che lui considera essere un oceano. Per quanto riguarda i mari, il Mar dei Caraibi subisce l'effetto massimo, mentre il Mar Rosso, probabilmente anche a causa della sua conformazione chiusa, è quello con l'aumento minore come risulta nella figura 1.6.

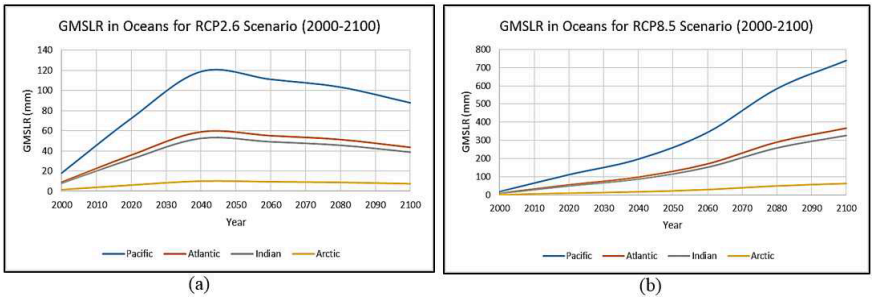

Figura 1.5: GMSLR negli oceani nello scenario migliore con RCP2.6 (a) e in quello peggiore con RCP pari a 8.5 (b). Fonte: Maddah (2016)

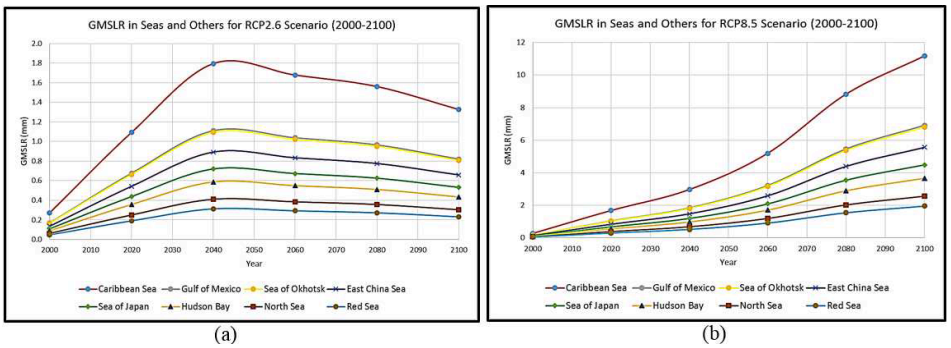

(a) (b)

Figura 1.6: GMSLR nei mari nello scenario migliore con RCP2.6 (a) e in quello peggiore con RCP pari a 8.5 (b). Fonte: Maddah (2016)

L'ultimo articolo analizzato in questa sezione del primo capitolo è il più recente tra quelli citati e si intitola "Fusion of probabilistic projections of Sea-Level Rise" (Grandey et al., 2024). Questo studio parte dal presupposto che non esista una sola proiezione universalmente valida del livello del mare e per questo motivo gli autori considerano i diversi workflow del sesto Assessment Report dell'IPCC, fondendoli con un sistema di pesatura. I workflows consistono in un insieme di dati e metodi usati per generare una proiezione della variabile di interesse, in questo caso il livello del mare.

La fusione probabilistica viene fatta con l'obiettivo di creare un modello che tenga conto al suo interno dell'ambiguità strutturale tra le fonti e che non si ponga come l'unico corretto, ma che al contrario rappresenti coerentemente il grado di fiducia che si può avere nelle diverse proiezioni esistenti. Il sistema di pesatura, che si basa sui quantili, è stato pensato per conservare anche le code della distribuzione, nonostante privilegi le osservazioni centrali.

All'interno dell'IPCC AR6 sono stati identificati quattro workflows, due dei quali son considerati a media e gli altri due a bassa confidenza e per la costruzione della distribuzione fusa finale serve combinarli in modo pesato.

Per questo motivo il nucleo centrale della distribuzione è costituito dai workflow a media confidenza, considerati i più affidabili. Tuttavia, per includere i contributi anche di quelli a bassa confidenza c'è bisogno di introdurre una struttura che quantifichi i margini dell'incertezza. A tal fine viene costruita una P-box (probability box), che definisce l'intervallo tra le distribuzioni cumulative minime e massime ottenute dai modelli a bassa confidenza, svolgendo il ruolo di limite esterno dell'incertezza.

La distribuzione centrale viene determinata con la media dei due workflow a media confidenza, considerata l'unica affidabile tra il 17° e l'83° percentile. Per quanto riguarda la costruzione delle code, si decide di integrare il contributo delle proiezioni più estreme con una

funzione di pesatura trapezoidale illustrata nella figura 1.7. A questo punto si ottiene una curva fusa coerente, continua ed interpretabile.

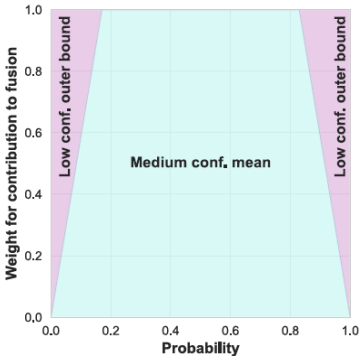

Figura 1.7: la funzione trapezoidale di peso tramite cui vengono combinati i workflows a bassa e media confidenza. Fonte: Grandey et al. (2024)

Come già fatto in precedenza da Maddah, anche in questo articolo le proiezioni del livello del mare vengono fatte considerando due scenari di emissioni differenti, ottenendo risultati diversi tra loro. Nel caso di basse emissioni, la mediana dell'innalzamento del mare risulta essere pari a circa 0.4 metri, con un 95° percentile che raggiunge 1 metro. Invece, nel caso di emissioni più elevate la mediana è di 0.8 metri, con un 95° percentile di 1.9 metri, delineando la possibilità, di conseguenze severe seppur molto remota (la probabilità che GMSLR superi il metro entro il 2100 è del 16%).

1.4 Conclusione ed obiettivi

All'interno di questo primo capitolo è stato ampiamente discusso e documentato il legame tra le emissioni di CO_2 e le trasformazioni ambientali su larga scala, in particolare l'espansione termica degli oceani e la fusione delle calotte glaciali. La rassegna della letteratura svolta sopra ha evidenziato come vi sia in atto un intenso dibattito modellistico per poter prevedere il livello del mare con il minor livello di rischio possibile. All'interno di questa discussione si sono sviluppati approcci differenti: da modelli probabilistici complessi a quelli che si fondano sulle relazioni paleoclimatiche di lungo periodo, fino a quelli più empirici come quello di Maddah. Ed è proprio quest'ultimo modello quello che più si avvicina a quello che verrà adoperato nella ricerca svolta e presentata in questo elaborato.

In particolare il presente lavoro si concentra sull'analisi delle serie storiche delle concentrazioni atmosferiche di CO_2 e del GMSL, con l'obiettivo di costruire un modello empirico che, interpolando le due serie, sia in grado di generare proiezioni attendibili, aggiornate e coerenti con i dati più recenti.

CAPITOLO 2 - Metodologie di Analisi e Modellazione delle Serie Storiche

2.1 Introduzione al capitolo

In questo capitolo vengono illustrate le principali tecniche adottate per lo studio delle serie storiche, elementi centrali di questa tesi. L'obiettivo è fornire una panoramica esaustiva degli strumenti metodologici e analitici necessari per comprendere le dinamiche temporali dei fenomeni osservati, il cui stato dell'arte è stato descritto nel capitolo precedente con lo scopo di contestualizzarli. Il quadro teorico che verrà delineato in questo capitolo rappresenta una base imprescindibile per interpretare i risultati ottenuti nei capitoli successivi, dedicati rispettivamente all'analisi preliminare dei dati e alla modellazione.

In primo luogo saranno presentate le definizioni di serie storica e le sue principali caratteristiche, come la stazionarietà (con gli appositi test per verificarne la presenza) e l'autocorrelazione.

Si passerà quindi alla descrizione della procedura di Box-Jenkins per la modellizzazione ARIMA, e per la sua estensione stagionale SARIMA (Box & Jenkins, 1976), fondamentali per l'analisi univariata e per la previsione delle serie storiche considerate.

Infine, nell'ultima parte del capitolo saranno approfondite le tecniche di analisi multivariata, introducendo concetti fondamentali quali la causalità (Granger, 1969) e la cointegrazione (Engle & Granger, 1987), insieme ai modelli specifici utilizzati per gestirli, che risultano necessari per l'analisi delle relazioni dinamiche tra le due serie temporali.

2.2 Serie Storiche e proprietà

Si chiama serie storica una certa collezione di osservazioni $\{x_t : t = 1,\dots, N\}$ riferite ad uno specifico fenomeno X_t, raccolte nel tempo ed indicizzate rispetto ad un parametro t (Brockwell & Davis, 2016). Il concetto di serie storica è strettamente legato a quello di processo stocastico, ovvero un modello che descrive un meccanismo generatore di numeri casuali nel tempo. In questa prospettiva, una serie storica x_t può essere vista come parte finita delle realizzazioni del processo stocastico X_t, ovvero il fenomeno a cui la serie è riferita.

In particolare i processi stocastici qui analizzati sono continui (si usano variabili di tipo continuo) e a parametro discreto, dal momento che i periodi di osservazione son discreti ed equispaziati (mensile, trimestrale, annuale, ecc.).

Per descrivere le caratteristiche fondamentali di un processo stocastico, è utile analizzarne i momenti, che forniscono misure sintetiche del comportamento della serie nel tempo. In particolare, il momento primo, ossia la media $\mu_t = E[X_t]$ (Wei, 2006), rappresenta il valore atteso della variabile casuale in ogni istante temporale t e descrive il livello medio attorno al quale si muovono le osservazioni.

Il momento secondo di una serie invece è la varianza $\sigma^2 = E[(X_t - \mu_t)^2]$ (Wei, 2006), indice che misura la volatilità dei valori rispetto alla media, fornendo indicazioni sulla variabilità di un fenomeno nel tempo.

Oltre ai momenti appena presentati, ne esiste uno che descrive la dipendenza lineare tra le osservazioni della serie a diversi istanti temporali, a distanza temporale h l'uno dall'altro: l'autocovarianza $Cov(X_t, X_{t+h}) = E[(X_t - \mu_t)\ (X_{t+h} - \mu_{t+h})]$ (Brockwell & Davis, 2016). La conoscenza teorica dei momenti è fondamentale per definire proprietà come la stazionarietà e le funzioni di autocorrelazione.

Ua processo stocastico si definisce stazionario in senso forte se tutte le funzioni di distribuzione che definiscono il processo rimangono inalterate qualora l'insieme dei punti temporali sia traslato lungo l'asse dei tempi di una certa quantità k: $F_{t_1,t_2,..,t_m}(x_1, ..., x_n) = F_{t_{1+k},t_{2+k},..,t_{m+k}}(x_1, ..., x_n)$ (Zavanella, 2005).

Dal momento che questo tipo di stazionarietà richiede che si verifichi un'ipotesi raramente verificabile nella realtà, l'analisi delle serie storiche fa comunemente ricorso ad una condizione meno limitante: la stazionarietà in senso debole. Si è in presenza di questa proprietà quando i momenti fino al secondo ordine (media e varianza) non dipendono da t, mentre l'autocovarianza dipende solamente dal valore della distanza h tra i due tempi considerati. Nel caso di serie stazionaria in senso debole si ha:

- $\mu_t = \mu \quad \forall t$
- $\sigma_t^2 = \gamma_0 = \sigma^2 < \infty \ \forall t \in \mathbf{Z}$
- $\gamma_h = Cov(X_t, X_{t+h}) \ \forall t, h \in \mathbf{Z}$

Nell'analisi delle serie storiche due misure importanti sono quelle fornite dalla funzione di autocorrelazione totale e da quella parziale. La funzione di autocorrelazione totale (denotata con ACF dall'inglese AutoCorrelation Function) misura la correlazione lineare tra due osservazioni della serie separate da un lag temporale k ed è così definita:

$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{cov(X_t, X_{t+k})}{var(X_t)}$ (Hamilton, 1994), ovvero il rapporto tra la covarianza tra le osservazioni in due istanti temporali differenti e la varianza del processo, che nel caso di una serie stazionaria è uguale in qualsiasi istante di tempo. ρ_k può assumere valori tra -1 e 1, permettendo di riconoscere correlazioni significative a diversi lag temporali.

La funzione di autocorrelazione ha 3 proprietà:

1. $\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$
2. Simmetria: $\rho_k = \rho_{-k}$
3. $|\rho_k| \leq 1$

Tuttavia può accadere che considerando due istanti temporali a distanza k, la correlazione tra questi venga influenzata da un lag temporale intermedio, cioè per un valore h<k. Per studiare l'autocorrelazione tra X_t e X_{t+k} depurata dai valori intermedi, si fa ricorso alla funzione di autocorrelazione parziale $\phi_{k,k}$ (PACF: Partial AutoCorrelation Function), in grado di quantificare la correlazione diretta tra due istanti temporali.

Queste funzioni vengono rappresentate graficamente tramite i correlogrammi, in cui sono visualizzati i valori dell'ACF e della PACF per diversi lag temporali. La presenza di eventuali picchi è sintomo di correlazioni significative tra i valori osservati a intervalli temporali differenti. Per l'intuitività nella lettura di tale rappresentazione grafica, l'analisi dei correlogrammi costituisce uno step fondamentale nella fase di identificazione del modello.

2.3 Procedura di Box - Jenkins

Nell'ambito delle serie storiche, per la costruzione e la stima dei modelli da adattare ai dati osservati si segue una successione di step predefinita: la Procedura di Box-Jenkins (Box & Jenkins, 1976). Questa metodologia si articola in 5 fasi principali di seguito elencate e successivamente approfondite:

1. Analisi grafica
2. Verifica della stazionarietà in media ed in varianza
3. Analisi dei correlogrammi
4. Stima del modello
5. Previsione

Nel corso di tutta questa procedura, è fondamentale il concetto di White Noise (rumore bianco), ovvero il più semplice processo stocastico: una sequenza di variabili casuali

indipendenti e identicamente distribuite con media zero e varianza costante, indicata con a_t e che rappresenta il rumore ideale che il modello deve lasciare nei residui dopo aver descritto la parte strutturale della serie.

L'obiettivo dell'applicazione di questi passaggi è quello di stimare ed identificare il modello che interpreti meglio i dati e la loro struttura. Questo si fonda sul presupposto fornito nel teorema di Wold: un qualsiasi processo stazionario X_t può essere rappresentato come somma tra una componente deterministica V_t ed una puramente stocastica Z_t, formata da una combinazione lineare di white noise: $X_t = V_t + Z_t$ (Wold, 1938).

2.3.1 Modelli Autoregressivi e a Media mobile

A partire dal teorema di Wold, i modelli più semplici e fondamentali per la rappresentazione dei processi stocastici sono i modelli autoregressivi (AR) e quelli a media mobile (MA). Essi costituiscono gli elementi più semplici per la costruzione dei modelli più generali utilizzati nella procedura di Box–Jenkins, definiti sotto l'ipotesi di stazionarietà della serie.

Si definisce autoregressivo un processo che fa dipendere l'osservazione presente dai valori di quelle passate, in particolare si dice che il processo è un AR(p) dove p è il ritardo massimo a cui si fa risalire la dipendenza di X_t. I modelli autoregressivi presentano la seguente struttura:

$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \ldots + \phi_p X_{t-p} + a_t = \Phi_p(B) X_t + a_t$ dove $a_t \sim WN(0, \sigma^2)$, Φ_p è il vettore dei coefficienti associati alle osservazioni passate, mentre B è l'operatore ritardo: $B^k X_t = X_{t-k}$ (Brockwell & Davis, 2016).

Se in un modello AR(p) il valore dell'osservazione al tempo t è visto come combinazione dei valori passati della stessa, in un modello a media mobile MA(q) X_t è visto come una combinazione lineare di q disturbi passati ponderati:

$X_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \ldots - \theta_q a_{t-q} = \Theta_q(B) a_t$, dove $a_t \sim WN(0, \sigma^2)$ (Brockwell & Davis, 2016). La tabella 2.1 contiene un riassunto delle principali proprietà dei modelli AR e MA.

	AR(p)	MA(q)
Stazionarietà	Radici del polinomio caratteristico all'esterno del cerchio unitario	Sempre garantita
ACF	Tende a zero esponenzialmente	Si spegne dopo il lag q
PACF	Si spegne dopo il lag p	Tende a zero esponenzialmente

Tabella 2.1: Principali caratteristiche dei modelli AR e MA

2.3.2 Modelli Misti, Integrati e Stagionali

I due modelli presentati in precedenza costituiscono due approcci complementari alla descrizione delle serie storiche in quanto ognuno dei due risulta utile a caratterizzare diverse tipologie di dipendenze temporali. Nonostante questo però, nella pratica applicativa possono risultare troppo rigidi: gli AR richiedono spesso ordini elevati per adattarsi correttamente ai dati, mentre gli MA da soli non sempre catturano in maniera efficace la struttura seriale osservata. Per ovviare a questa problematica, è stato inventato un modello misto ARMA(p,q) in cui coesistessero le 2 componenti. Questo modello si presenta nella seguente forma:

$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$, oppure scritto in forma compatta risulta essere: $\Phi_p(B)X_t = \Theta_q(B)a_t$ (Box e Jenkins, 1976).

Il modello ARMA(p,q) risulta essere stazionario se lo è la sua componente autoregressiva e quindi se le radici del polinomio caratteristico giacciono al di fuori del cerchio unitario.

Inoltre, la funzione di autocorrelazione di un processo ARMA(p,q) mostra valori che dipendono congiuntamente sia dai parametri autoregressivi che da quelli a media mobile. Analogamente, la funzione di autocorrelazione parziale non presenta un comportamento semplice come nei modelli puramente AR o puramente MA. Essendo infatti un modello misto, le proprietà tipiche delle due componenti risultano mitigate dagli effetti dell'altra: la ACF non si annulla dopo un certo lag come negli MA, né decresce regolarmente come negli AR, mentre la PACF non mostra un taglio netto. Ne consegue che, nei modelli ARMA, nessuna delle due funzioni si comporta in maniera "pulita" ed evidente. Tuttavia, l'analisi dei correlogrammi resta uno strumento essenziale, in quanto consente di formulare ipotesi sugli ordini p e q, che verranno poi verificati e raffinati nelle fasi successive della procedura di Box-Jenkins.

Come già evidenziato nella descrizione dei modelli AR e MA, anche per il modello misto ARMA uno dei requisiti fondamentali è la stazionarietà della serie a cui viene applicato.

Senza tale condizione, infatti, le proprietà teoriche del modello non risultano valide e le stime dei parametri possono risultare fuorvianti. Per questo motivo, la prima fase della procedura di Box–Jenkins assume un ruolo cruciale, in quanto consente di verificare la presenza di eventuali trend di lungo periodo o di oscillazioni con varianza non costante, entrambe manifestazioni tipiche di non stazionarietà. In tali circostanze, si ricorre a trasformazioni e operazioni di differenziazione, che permettono di rendere la serie stazionaria e di estendere i modelli ARMA ai più generali modelli ARIMA. La differenziazione di primo ordine è data da $\Delta X_t = (1 - B)X_t = X_t - X_{t-1}$, più in generale la differenziazione del d-esimo ordine è data da $\Delta^d X_t = (1 - B)^d X_t$. Un aspetto da considerare è che l'operazione di differenziazione riduce il numero di osservazioni disponibili per l'analisi: una differenza di ordine d comporta infatti la perdita delle prime d osservazioni della serie.

L'inclusione della differenziazione all'interno di un modello ARMA porta alla definizione del modello ARIMA(p,d,q) (Autoregressive Integrated Moving Average), in cui d indica il numero di differenze necessarie a rendere stazionaria la serie. In termini formali, un modello ARIMA può essere scritto come: $\Phi_p(B)(1 - B)^d X_t = \Theta_q(B)a_t$ (Box & Jenkins, 1976).

Un caso particolare di processo ARIMA, e anche il più semplice, si chiama Random Walk (RW) ed è formulato come un ARIMA(0,1,0): $X_t = X_{t-1} + a_t$ (Zavanella, 2005). Nel caso in cui venga aggiunta di una costante δ, si chiama RW con drift: $X_t = X_{t-1} + a_t + \delta$.

La scelta di introdurre o meno un'operazione di differenziazione all'interno del modello dipende dalla verifica della presenza di radici unitarie, che costituiscono una delle cause principali di non stazionarietà. Per questo motivo, si ricorre all'applicazione del test di Dickey–Fuller, uno degli strumenti più diffusi per valutare l'adozione di un modello ARIMA (Dickey & Fuller, 1979). Questo è un test di non stazionarietà, così chiamato dal momento che l'ipotesi nulla assume che la serie a cui il modello viene applicato non sia stazionaria e che vi sia dunque una radice unitaria, mentre l'ipotesi alternativa sostiene che la serie sia stazionaria.

Il modello di riferimento per il test di Dickey Fuller (ADF) è il seguente: $(X_t - CD_t) = \alpha(X_{t-1} - CD_{t-1}) + a_t$ dove a_t è un rumore bianco e CD_t rappresenta una componente deterministica che può assumere 3 specificazioni, e di conseguenze dare vita a 3 diverse formulazioni al test:

1. Caso 1, è nulla, $CD_t = 0$. Il modello diventa: $X_t = \alpha X_{t-1} + a_t$

2. Caso 2, è costante, $CD_t = k$.
3. Caso 3, è lineare, $CD_t = k + \delta t$

In tutti e 3 i casi l'attenzione è focalizzata sul valore del coefficiente α che l'ipotesi nulla considera essere = 1 (serie non stazionaria), mentre l'ipotesi alternativa sostiene che sia minore di 1 in modulo (serie stazionaria). La statistica test in tutti e 3 i casi è così formulata: $\tau = \frac{\hat{\alpha}}{SE(\hat{\alpha})}$ dove $\hat{\alpha}$ è lo stimatore del parametro e SE è il suo errore standard. Il valore ottenuto di τ viene confrontato con le tabelle critiche di Dickey-Fuller (Dickey & Fuller, 1979).

L'analisi grafica della serie e dei correlogrammi può rivelarsi utile anche per la rilevazione della presenza di stagionalità. La stagionalità si manifesta infatti attraverso andamenti ciclici ricorrenti a intervalli regolari nel tempo, come picchi e cavi che si ripetono annualmente, trimestralmente o mensilmente a seconda della natura dei dati. Questi comportamenti, spesso visibili in un semplice grafico della serie, rappresentano oscillazioni sistematiche legate a fattori esterni periodici, nel caso delle serie climatiche ed ambientali ad esempio si notano spesso comportamenti sistematici dovuti alle stagioni.

All'interno dei correlogrammi invece la stagionalità si manifesta tramite picchi significativi a lag multipli del periodo stagionale s.

Dal momento che i modelli ARIMA non sono in grado di cogliere adeguatamente queste dinamiche, è necessario adottare una loro estensione che tenga conto della componente stagionale: i SARIMA(p,d,q)x(P,D,Q) (Seasonal ARIMA), con le lettere maiuscole che costituiscono gli ordini stagionali. La scrittura in forma compatta del modello risulta essere:

$\Phi_p(B)\Phi_P(B^s)(1 - B)^d(1 - B^s)^D X_t = \Theta_q(B)\Theta_Q(B^s)a_t$ (Box & Jenkins, 1976), dove:

- p,d,q rappresentano gli ordini dell'ARIMA
- P,D,Q rappresentano gli ordini stagionali
- s indica il periodo stagionale
- $\Phi_P(B^s)$ e $\Theta_Q(B^s)$ sono i polinomi stagionali autoregressivi e a media mobile
- $(1 - B^s)^D$ è l'operatore di differenziazione stagionale di ordine D.

2.3.3 Stima di parametri e criteri di scelta

Elencate le diverse specificazioni che i modelli ARIMA possono assumere, verrà ora descritta la metodologia di stima dei parametri del modello, necessaria per valutare l'adeguatezza nell'adattamento ai dati. Si tratta dunque di trovare un metodo per stimare i vettori di parametri autoregressivi $\phi = (\phi_1, \ldots, \phi_p)$ e a media mobile $\theta = (\theta_1, \ldots, \theta_p)$.

Il metodo utilizzato, e anche il più diffuso nell'ambito della stima degli ARIMA, è quello della Massima Verosomiglianza (Maximum Likelihood Estimation, MLE). Ciò si fonda sull'idea di individuare i valori dei parametri che rendono massima la probabilità di osservare i dati campionari effettivamente rilevati.

Chiamata X la serie osservata e β l'insieme dei parametri da stimare, la funzione di verosimiglianza è data da $L(\beta|X) = f(X_1,\ldots,X_T|\beta)$ (Wei, 2006), f() rappresenta la densità congiunta delle osservazioni, che dipende dalla distribuzione assunta per i termini di errore a_t, che si ipotizza essere di solito un rumore bianco gaussiano con media nulla e varianza costante.

Nella pratica, per poter gestire più facilmente determinate strutture (prodotto delle densità) della funzione di verosimiglianza dal punto di vista analitico, si lavora sulla forma logaritmica di essa, la log verosimiglianza. Di conseguenza, i parametri β che massimizzano la log-verosimiglianza risultano essere $\hat{\beta} = argmax\, l(\beta|X)$. All'interno della stima dei modelli autoregressivi e a media mobile questa espressione porta ad un sistema di equazioni non lineari, per questo motivo si è soliti ricorrere a metodi numerici iterativi.

Un vantaggio fondamentale dell'utilizzo della MLE è la possibilità di condurre inferenza statistica sui parametri stimati: sotto opportune condizioni, infatti, le stime risultano consistenti, asintoticamente normali ed efficienti, consentendo quindi la costruzione di intervalli di confidenza e test di ipotesi affidabili.

Nella quarta fase della procedura di Box–Jenkins diventa fondamentale la scelta del modello più appropriato: una volta stimati i parametri, occorre infatti individuare la specificazione che meglio rappresenta i dati, facendo ricorso a criteri che bilanciano la bontà di adattamento con la parsimonia del modello.

Nel caso dell'analisi delle serie storiche non si può utilizzare il coefficiente di determinazione R^2, dal momento che costituisce una misura intrinseca della capacità predittiva del modello analizzato e non dipende direttamente dai dati osservati. Per questa ragione i criteri maggiormente utilizzati sono il criterio di Schwartz, SBC (Schwarz, 1978), ed il criterio di informazione di Akaike, AIC (Akaike, 1974). In questo elaborato si è adottato quest'ultimo

privilegiando quindi, a parità di adeguatezza, il modello più parsimonioso, ossia quello con l'AIC minore. Infatti tale indice, per come è stato costruito, penalizza l'utilizzo di un eccessivo numero di parametri. Questa la formula dell'AIC: $AIC(M) = -2logL(\beta) + 2M$ (Akaike, 1974).

Indicato con M il numero di parametri stimati, e contrapposto il valore della massima verosimiglianza fornita dal modello stesso, l'AIC diminuisce solo se l'aggiunta di parametri comporta un reale incremento della verosimiglianza. In caso contrario, l'indice cresce, segnalando una minore efficienza del modello e quindi l'inutilità della complessità introdotta.

2.3.4 Diagnostica dei residui

La quarta fase della procedura di Box-Jenkins, per potersi ritenere conclusa, richiede che il modello stimato soddisfi alcune ipotesi. In particolare è richiesto che i residui $\widehat{a}_t$, ovvero le stime dei white noise non osservati, siano normali ed incorrelati (Brockwell & Davis, 2016).

Per verificare che i residui abbiano media nulla e varianza costante si hanno a disposizione due strumenti:

- visualizzazione dell'istogramma dei residui standardizzati, da confrontare con una distribuzione normale standard
- test di normalità di Jarque-Bera, che deve avere un p-value superiore al valore soglia α (Jarque & Bera, 1980).

Per la verifica dell'assenza di autocorrelazione nei residui si adopera il test di Ljung-Box che valuta se le singole autocorrelazioni residue sono significativamente diverse da 0 fino ad un lag k (Ljung & Box, 1978). La statistica test è definita come $Q = n(n+2)\sum_{k=1}^{h}\frac{\widehat{\rho}_k^2}{n-k}$ dove k è il numero di lag, n è la numerosità campionaria e $\widehat{\rho}_k$ il coefficiente di autocorrelazione.

Sotto H_0 che prevede che i residui siano white noise, la statistica Q è distribuita come una χ^2_{h-p-q} dove $h-p-q$ sono i gradi di libertà: h è il lag massimo su cui viene testata l'autocorrelazione, mentre p e q sono gli ordini del modello stimato. Un valore del p-value superiore al livello di significatività α implica l'assenza di evidenza contro l'ipotesi nulla e quindi i residui possono considerarsi incorrelati, ritenendo conclusa la diagnostica.

2.3.5 Previsione

L'ultimo step della procedura di Box-Jenkins è la previsione, dove l'osservazione X_{t+h} (h è l'orizzonte previsionale) viene stimata tramite la funzione in grado di minimizzare l'errore quadratico medio. La funzione in questione è il valore atteso condizionato e commette un errore di previsione: $e_{t+h|t} = X_{t+h} - \widehat{X_{t+h}}$, dato dai white noise di ordine da t+1 a t+h, in quanto considerati per costruzione nulli, pari cioè al loro valore atteso, ma che in realtà nulli non sono. Applicando il valore atteso all'errore di previsione, si ottiene anche in questo caso 0, valore del momento primo di e_t. Si può inoltre calcolare la varianza, pari a: $\sigma^2_{e_t} = E\left(X_{t+h} - \widehat{X_{t+h}}\right)^2 = \sigma^2_a(1 + \psi^2_1 + ... + \psi^2_{h-1})$. Infatti la differenza tra il valore effettivo e la previsione è dato solamente dai rumori bianchi e di conseguenza la varianza dell'errore è dovuta semplicemente alla varianza dei white noise.

Calcolata la varianza dell'errore di previsione ed utilizzando il quantile della normale standard $z_{\frac{\alpha}{2}}$, è possibile derivare i limiti dell'intervallo di previsione:

$$\widehat{X_{t+h}} - z_{\frac{\alpha}{2}}\sqrt{\sigma^2_{e_t}} \leq X_{t+h} \leq \widehat{X_{t+h}} + z_{\frac{\alpha}{2}}\sqrt{\sigma^2_{e_t}}$$

Dal momento che una delle condizioni del teorema di Wold assicura che $\sum_{j=0}^{\infty} \psi^2_j < \infty$ (Wold, 1938), segue che $\lim_{j \to \infty} \psi_j = 0$ e quindi: $\lim_{h \to \infty} \widehat{X_{t+h}} = \lim_{h \to \infty} \psi_h \widehat{a_t} + \psi_{h+1}\widehat{a_{t-1}} + ... = 0$. Si può dunque notare una tendenza della previsione a convergere verso la media della serie a lungo termine, pari cioè a 0.

Nella tabella 2.2 si possono trovare elencate le principali caratteristiche della previsione nei modelli AR, MA, ARIMA e ARIMA.

	Previsione
AR(p)	Combinazione lineare dei valori passati stimati
MA(q)	Fino al lag q la previsione dipende dagli shock noti fino al tempo t, dopo si spegne
ARMA(p,q)	Combinazione dei valori passati e degli shock noti
ARIMA(p,d,q)	Applicata la differenziazione, si prevede sulla serie stazionaria ed in seguito si ricostruisce la previsione tramite somma cumulata
SARIMA(P,D,Q)x(p,d,q)	Applicata la differenziazione non stagionale (d) e quella stagionale (D), si prevede sulla serie resa stazionaria; successivamente si ricostruisce la previsione tramite somma cumulata e reinserendo la componente stagionale

Tabella 2.2: costruzione della previsione nei vari modelli

2.4 Serie Multivariate, Causalità e VAR

Finora sono state presentate proprietà e tecniche di analisi dedicate esclusivamente a serie storiche univariate, ovvero riguardanti solamente un certo fenomeno. Da ora fino al termine del capitolo 2 verranno presentate metodologie incentrate sullo studio delle serie storiche multivariate. Per serie storica multivariata a k dimensioni si intende un insieme di k serie storiche univariate, ciascuna indicizzata rispetto allo stesso parametro temporale $t \in T$, dove T è un insieme numerabile, la cui cardinalità rappresenta la lunghezza della serie storica.

Una serie storica multivariata $x_1, \ldots, x_n$, con $x_t = [x_{1t}, \ldots, x_{kt}]$ è considerata la realizzazione finita di un processo stocastico multivariato $\{X_t\}_{|t|=0}^{\infty}$, dove X_t sono variabili casuali a k dimensioni (Brockwell & Davis, 2016). Analogamente al caso univariato, un processo stocastico multivariato è caratterizzato dal momento primo (il vettore delle medie) e dalla funzione di covarianza (ora espressa dalla matrice di varianze e covarianze). La differenza principale consiste quindi nel fatto che, a causa della natura multivariata della serie, anche concetti come il white noise si estendono in senso vettoriale. La proprietà di stazionarietà, infine, rimane invariata, ma va riferita al vettore delle medie e alla matrice delle autocovarianze.

Nell'analisi delle serie storiche multivariate diventa fondamentale indagare le relazioni di interdipendenza e di causalità tra più processi. In particolare, una delle questioni più rilevanti

è stabilire se e in che misura l'evoluzione di una serie X_t possa fornire informazioni utili per la previsione di un'altra serie Y_t, è in questo contesto che si inserisce il concetto di "Causalità di Granger" (Granger, 1969).

Formalmente, si dice che una serie X_t "Granger-causa" Y_t se i valori passati della prima serie contribuiscono in maniera significativa a spiegare la variabilità futura della seconda, già spiegata attraverso il suo passato. Il test di Granger si fonda sul confronto tra due modelli autoregressivi: il primo è detto "modello ristretto" e contiene solamente i valori passati della variabile Y_t, il secondo invece è il "modello esteso" e include anche i valori passati della variabile X_t. L'idea che sta dietro al test è quella di verificare se i coefficienti β_j associati ai valori passati della serie X_t risultino essere statisticamente significativi, suggerendo un miglioramento nelle capacità predittive del modello e dunque una causalità di Granger. Per fare ciò viene calcolata la somma dei quadrati dei residui (RSS) di entrambi i modelli e conseguentemente viene calcolata la statistica F di confronto e, se questa risulta essere minore del livello di significatività prefissato, viene rifiutata l'ipotesi nulla che sostiene l'assenza di causalità (Granger, 1969). È importante specificare però che la causalità di Granger non implica un rapporto causale vero e proprio, bensì una relazione di precedenza temporale e capacità predittiva e lo fa indicando la direzione di influenza tra variabili, motivo per cui il test rappresenta un passo cruciale nell'analisi multivariata.

La relazione tra serie storiche viene formalizzata attraverso i modelli autoregressivi vettoriali (VAR), che rappresentano l'estensione multivariata dei modelli AR (Zavanella, 2015). Proprio i VAR costituiscono lo strumento fondamentale per il test di Granger: il modello ristretto è un VAR che include solo la variabile Y_t, mentre il modello esteso incorpora anche X_t.

Se si considerano X_t e Y_t far parte del vettore delle variabili X_t, allora il modello VAR(p) è così strutturato:

$X_t = \Phi_1 X_{t-1} + \dots + \Phi_p X_{t-p} + a_t$, in forma compatta: $\Phi(B)X_t = a_t$ (Zavanella, 2015). All'interno di queste espressioni X_t è il vettore di dimensione k contenente le variabili, $\Phi_1 \dots \Phi_p$ sono delle matrici di coefficienti di dimensioni $k \times k$ ed infine a_t è il white noise vettoriale di media nulla e matrice di covarianza Σa.

Nei modelli VAR è cruciale la scelta ottimale del numero di ritardi p, ovvero il numero di lag da includere per ciascuna variabile. Questo avviene tramite la procedura VARselect che

confronta diverse specificazioni del modello con ordini differenti, utilizzando criteri informativi analoghi a quelli dei modelli ARIMA (AIC e SBC) (Lutkepohl, 2005).
Una volta stimato il VAR(p) con l'ordine ottimale, è poi possibile utilizzarlo per effettuare previsioni multivariate. La logica è la stessa dei modelli univariati: il valore futuro di ciascuna variabile X_{t+h} viene approssimato tramite la combinazione lineare dei valori passati di tutte le variabili nel sistema, utilizzando i coefficienti stimati e, per previsioni a più passi, si usano ricorsivamente i valori predetti per sostituire le osservazioni future.
Anche in questo caso, come in quello univariato, nell'effettuare la previsione si commette un errore dovuto al vettore dei white noise negli istanti futuri. A questo errore è associata una matrice di covarianza che consente la costruzione di intervalli di confidenza per ciascuna variabile e di analizzare l'incertezza associata alle previsioni.
Infine, un aspetto cruciale è la condizione di stazionarietà del processo VAR: affinché il modello sia ben definito e produca previsioni stabili, le radici del polinomio caratteristico devono trovarsi all'esterno del cerchio unitario. In caso contrario, il sistema risulta instabile e si rende necessario ricorrere a trasformazioni o a considerare il concetto di cointegrazione, con i modelli associati ad esso (VECM).

2.5 Cointegrazione e VECM

Nell'analisi delle serie storiche è frequente avere a che fare con variabili non stazionarie in un primo momento, ma che lo diventano in seguito ad opportune differenziazioni, dette per questa ragione "integrate di ordine c" I(c), dove c è il numero di differenziazioni necessarie a renderle stazionarie. È in questo contesto che si inserisce il concetto di cointegrazione.
Una serie storica multivariata $X_t = [X_{1t},..., X_{kt}]$ è detta cointegrata se ogni singola componente del vettore è una serie storica I(1) ed esiste almeno un vettore di pesi $a = [a_1,..., a_k]$ tale per cui la serie storica ottenuta come combinazione lineare del vettore risulti stazionaria: $Z_t = a'X_t = I(0)$. Il vettore a è detto vettore di cointegrazione e non è unico, infatti se Z_t è stazionaria, allora per qualsiasi scalare β risulta essere stazionaria anche $\beta a'X_t$, solamente per k=2 è possibile ottenere un unico vettore di cointegrazione normalizzando a 1 la prima componente di a (Engle & Granger, 1987).
Per testare la presenza di cointegrazione si possono usare due test diversi in base al numero di serie analizzate: generalmente viene adoperato il test di Johansen (Johansen, 1988), ma nel

caso in cui le variabili siano solamente 2 come nella presente tesi si usa il test di Engle-Granger (Engle & Granger, 1987).

La procedura di questo test si articola in due fasi: viene in un primo momento effettuata una regressione della prima variabile Y_t sulla seconda X_t: $Y_t = \alpha + \beta X_t + u_t$, salvando i residui $\widehat{u_t}$. In seguito si applica un test ADF proprio su $\widehat{u_t}$ (Dickey & Fuller, 1979), H_0 sostiene che i residui abbiano una radice unitaria, mostrando come non siano stazionari e di conseguenza le serie non siano cointegrate. H_1 afferma invece il contrario, sostenendo dunque la stazionarietà dei residui e la cointegrazione delle serie; per questo motivo la relazione di lungo periodo è confermata solamente nel caso in cui il p-value risulti minore della soglia di significatività precedentemente stabilita, portando a rifiutare H_0.

In presenza di sistemi cointegrati, l'approccio più generale per rappresentarne le dinamiche è il Vector Error Correction Model (VECM), che costituisce una riformulazione del VAR in differenze prime con l'aggiunta di un termine di correzione dell'errore (Zavanella, 2015). La logica alla base di tale modello è che l'evoluzione di breve periodo di ciascuna variabile dipende non solo dalle proprie variazioni passate e da quelle delle altre variabili del sistema, ma anche dal grado di disequilibrio rispetto alla relazione di lungo periodo individuata dal vettore (o dai vettori) di cointegrazione. Nel caso particolare in cui il sistema sia formato da sole due variabili, il VECM si riduce a un Error Correction Model (ECM), in cui la variazione di breve periodo della variabile dipendente è spiegata sia dalle variazioni ritardate delle variabili coinvolte, sia dal termine di correzione dell'errore derivante dalla relazione di cointegrazione.

Per ottenere un VECM, bisogna partire da un VAR(p) dove le variabili contenute nel vettore X_t di dimensione $k \times 1$ sono I(1): $X_t = \Phi_1 X_{t-1} + \dots + \Phi_p X_{t-p} + a_t$.

Sottraendo X_{t-1} da entrambi i lati si ottiene $\Delta X_t = (\Phi_1 - I)X_{t-1} + \dots + \Phi_p X_{t-p} + a_t$, dove chiamo $\Pi = (\Phi_1 - I)$ (Lutkepohl, 2005).

In questo momento nella parte destra dell'equazione ho tutti i termini in livelli, ma l'intenzione è quella di ottenere solamente il primo lag in livelli in quanto cattura il disequilibrio di lungo periodo, il resto dei termini li voglio in differenze affinchè catturino le dinamiche di breve periodo. A questo fine vengono ora usate alcune tecniche algebriche in grado di favorire la scrittura che ci si è prefissati per la creazione del modello VECM.

Sapendo che la differenza del livello di una variabile ad un determinato istante t equivale a $\Delta X_t = X_t - X_{t-1}$, è possibile riscrivere il livello ad un generico istante $t - 2$ come $X_{t-2} = X_{t-1} - \Delta X_{t-1}$. Per questa ragione all'interno dell'equazione verranno aggiunti e sottratti $\Phi_2 X_{t-1}$, $\Phi_3 X_{t-2}$,... in base al numero p di ritardi, fornendo sempre la possibilità di scrivere le variabili, tranne X_{t-1}, come differenza. Ciò è possibile osservarlo nel caso illustrato di seguito, in cui p è considerato pari a 3, e dunque la struttura del modello appare inizialmente come: $\Delta X_t = \Pi X_{t-1} + \Phi_2 X_{t-2} + \Phi_3 X_{t-3} + a_t$. A questa equazione vado ad aggiungere e sottrarre le seguenti quantità: $\Phi_2 X_{t-1}$, $\Phi_3 X_{t-1}$, $\Phi_3 X_{t-2}$, in modo da ottenere le seguenti differenze: $\Phi_2 X_{t-2} = \Phi_2 (X_{t-1} - \Delta X_{t-1})$, $\Phi_3 X_{t-3} = \Phi_3 (X_{t-1} - \Delta X_{t-1} - \Delta X_{t-2})$.
Una volta aggiunte le quantità sopra elencate ottengo un'equazione così strutturata in forma compatta: $\Delta X_t = \Pi X_{t-1} + \Gamma_1 \Delta X_{t-1} + \Gamma_2 \Delta X_{t-2} + a_t$, dove queste sono le grandezze:

- $\Pi = (\Phi_1 + \Phi_2 + \Phi_3 - I)$
- $\Gamma_1 = -(\Phi_2 + \Phi_3)$
- $\Gamma_2 = -\Phi_3$

Estendendo il modello al caso generale, un VAR(p) in forma compatta appare come

$$\Delta X_t = \Pi X_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta X_{t-i} + a_t, \text{ dove } \Pi = (\sum_{i=1}^{p} \Phi_i) - I, \Gamma_i = -(\sum_{j=i+1}^{p} \Phi_j)$$

I termini $\sum_{i=1}^{p-1} \Gamma_i \Delta X_{t-i}$ catturano la dinamica di breve periodo, invece ΠX_{t-1} cattura l'informazione di lungo periodo (Lutkepohl, 2005).
Per comprendere se il framework in cui si sta lavorando sia effettivamente un sistema di cointegrazione bisogna studiare il rango di Π (Johansen, 1988):

- $rango(\Pi) = 0$: nessuna relazione di lungo periodo, nessun termine di correzione appare significativo
- $rango(\Pi) = k$: X_t è stazionario in livelli, si torna ad un VAR.
- $0 < rango(\Pi) = r < k$: esistono r relazioni di cointegrazione e si può fattorizzare $\Pi = \alpha\beta'$ dove β è una matrice $k \times r$ dove i vettori colonna sono vettori di cointegrazione e α è una matrice detta di "velocità di aggiustamento".

Come anche i modelli analizzati in precedenza, anche ECM contribuisce alla previsione dei valori futuri. Se i modelli precedentemente analizzati fornivano direttamente i livelli futuri,

questo modello non lo fa, ma fornisce la correzione necessaria per far sì che la previsione one-step ahead sia coerente con la dinamica di breve e con il vincolo di lungo periodo. Tutto ciò avviene tramite il calcolo del fattore di correzione $\widehat{\Delta y_{t+1}}$ a partire dalla struttura dell'ECM (Engle & Granger, 1987). Questo termine, una volta ricavato, viene sommato alla realizzazione corrente y_t per poi andare ad ottenere la previsione di y_{t+1}.

2.6 ARDL

L'ultimo modello trattato in questo capitolo permette di modellare simultaneamente le interazioni di breve e di lungo periodo e non richiede la cointegrazione delle serie a cui è applicato. Si tratta dell'Autoregressive Distributed Lag (ARDL) ed è in continuità con i modelli presentati in precedenza, come esposto di seguito e nella tabella 2.3:

- Come il modello VAR, anche i modelli ARDL includono ritardi delle variabili dipendenti ed esplicative, catturando le interdipendenze dinamiche attraverso più lag (Pesaran et al, 2001). La differenza tra i due sta nel fatto che l'ARDL sia un modello di regressione che mantiene una distinzione tra variabile dipendente ed esplicative, che possono essere sia endogene che esogene, a differenza dei VAR che trattano tutte le variabili come endogene.
- Il legame con gli ECM emerge dal fatto che un ARDL, opportunamente riscritto assume la forma di un modello a correzione dell'errore, consentendo di stimare la dinamica di breve e la relazione di lungo periodo. La differenza tra i due giace nel fatto che l'ARDL si presta ad applicazioni anche in presenza di variabili I(0) e non solamente I(1) (Engle & Granger, 1987).

Dal punto di vista formale un modello ARDL(p,q), con variabile dipendente Y_t con p lag ed esplicativa X_t con q lag, può essere espresso come: $Y_t = \alpha_0 + \sum_{i=0}^{p} \beta_i Y_{t-i} + \sum_{j=0}^{q} \alpha_j X_{t-j} + a_t$ (Pesaran et al., 2001).

Considerando la variabile X_t come esogena, per effettuare previsioni di Y_t tramite un modello ARDL è necessario conoscere i valori futuri di X_t , o perlomeno stimarli e a quel punto la previsione diventa:

$\widehat{Y_{t+1}} = \widehat{\alpha_0} + \sum_{i=0}^{p} \widehat{\beta_i} Y_{t+1-i} + \sum_{j=0}^{q} \widehat{\alpha_j} X_{t+1-j}$ (Lutkepohl, 2005).

	Struttura
VAR(p)	Tutte le variabili sono endogene e dipendono dai propri lag e da quelli delle altre
ECM	Relazione in differenze e termine di correzione dell'errore
ARDL(p,q)	Il livello della variabile endogena si compone dei propri ritardi e di quelli della variabile esogena.

Tabella 2.3: Principali caratteristiche dei modelli multivariati

2.7 Conclusione

In questo capitolo sono state presentate le principali tecniche di analisi e modellazione delle serie storiche, con l'obiettivo di fornire una panoramica teorica solida su cui basare le applicazioni successive. L'attenzione si è concentrata dapprima sui modelli univariati, quali AR, MA e ARIMA, che consentono di descrivere l'evoluzione di una singola variabile nel tempo, affrontando aspetti centrali come la stazionarietà, la stagionalità e le trasformazioni necessarie a rendere le serie più facilmente modellabili. Sono stati inoltre analizzati i criteri di scelta del modello più adeguato e le procedure diagnostiche sui residui, per poi arrivare all'ultimo passaggio della procedura di Box–Jenkins, ossia la previsione, che costituisce lo scopo ultimo della modellizzazione.

Successivamente, l'analisi si è estesa alle serie multivariate, introducendo modelli in grado di cogliere le interrelazioni tra più variabili osservate simultaneamente. In particolare, sono stati approfonditi i modelli VAR, che rappresentano l'estensione naturale degli AR al caso vettoriale, i VECM, che permettono di integrare la presenza di relazioni di lungo periodo attraverso la cointegrazione, e infine i modelli ARDL, che si prestano ad analizzare dinamiche sia di breve che di lungo periodo con un approccio particolarmente flessibile.

L'insieme di queste metodologie consente non solo di descrivere e interpretare il comportamento delle serie storiche, ma anche di produrre previsioni, valutandone l'affidabilità e stimando l'incertezza associata. Nei prossimi capitoli, tali strumenti verranno applicati ai dati oggetto di studio, così da verificare empiricamente quanto emerso a livello teorico e discutere i risultati ottenuti.

CAPITOLO 3 - Dati e Preprocessing

3.1: Introduzione al Capitolo: Scopo e metodi

In questo capitolo vengono descritti i dataset analizzati, le variabili chiave ed i metodi impiegati per preparare i dati per le successive e più robuste analisi. Qui verrà introdotto sia il framework empirico su cui si fonda la ricerca che anche le procedure di preprocessing adottate per garantire l'idoneità dei dati all'analisi statistica.

L'obiettivo di questo capitolo è quello di verificare la presenza di proprietà statistiche fondamentali, necessarie come presupposto per alcuni dei modelli di serie storiche che verranno sviluppati nel capitolo seguente. In particolare sono state analizzate la stazionarietà e la stagionalità delle due serie storiche considerate e, nel caso in cui queste proprietà non fossero state rispettate, si è provveduto ad applicarvi le trasformazioni necessarie.

Per fare ciò ci si è avvalsi di tecniche numeriche, test statistici e anche di analisi grafiche come i correlogrammi o l'andamento della serie (ts.plot).

Tutta l'elaborazione è stata svolta nell'ambiente RStudio, di cui sono state sfruttate alcune librerie: tseries per le analisi mediante tecniche di serie storiche, dplyr per la manipolazione dei dati e la libreria ggplot2 per la visualizzazione.

Inoltre sono state sviluppate ed utilizzate due funzioni R personalizzate per la generazione di correlogrammi orientati verticalmente e per la creazione di "seasplot" (seasonal plot), grafici in cui viene mostrato come l'andamento medio di una serie cambi nei vari mesi dell'anno, evidenziando eventuali stagionalità laddove queste siano presenti.

3.2: Descrizione dei Dataset e Preprocessing

Questo paragrafo è dedicato alla presentazione dei dataset impiegati per condurre l'analisi centrale in questa tesi. Verranno illustrate le caratteristiche principali di ciascuna serie storica, le fonti da cui sono state acquisite, il periodo e la frequenza di osservazione ed infine l'unità di misura.

Entrambi i dataset sono stati ottenuti dal portale gestito dalla National Aeronautics and Space Administration (NASA) e chiamato "Climate Change: Vital Signs of the planet". Questo sito web costituisce una risorsa fondamentale e liberamente accessibile per la comprensione dei cambiamenti climatici. Ha l'obiettivo di fornire una panoramica aggiornata sugli indicatori chiave della salute climatica del pianeta, tramite dati derivanti da osservazioni satellitari e misurazioni di lungo periodo di indicatori quali la concentrazione di Anidride Carbonica,

Livello del Mare (GMSL), Temperatura globale, Estensione delle Calotte Glaciali, temperatura degli oceani. Oltre a fornire serie storiche dettagliate, spesso disponibili in più versioni per lo stesso indicatore (ad esempio il gmsl con applicata la correzione gia, ma anche senza), questo portale offre analisi accurate accompagnate da grafici interattivi.

Il dataset relativo alla concentrazione atmosferica di anidride carbonica è stato trovato all'interno del portale menzionato sopra, in particolare era contenuto dentro la sezione dedicata al "Carbon Dioxide" e accessibile tramite il seguente link: https://climate.nasa.gov/vital-signs/carbon-dioxide/?intent=121.
Questa serie storica contiene misurazioni condotte presso il Mauna Loa Observatory situato alle Isole Hawaii sull'omonimo vulcano di Mauna Loa. Le misurazioni sono state svolte con cadenza mensile a partire da marzo del 1958 e sono espresse in parti per milione (ppm), ovvero il numero di molecole di anidride carbonica per milione di molecole di aria secca e il livello di riferimento con cui vengono effettuati i confronti è quello preindustriale di 280 ppm. Le misurazioni all'osservatorio vengono svolte campionando l'aria di continuo e hanno subito una sola interruzione dall'inizio delle rilevazioni, come indicato in una nota all'inizio del dataset. Un'eruzione vulcanica ha infatti fatto sì che tra il 29 novembre 2022 e il 4 luglio 2023 le osservazioni fossero effettuate da un sito alternativo, il Maunakea Observatories, garantendo comunque la continuità della serie. Oltre alle rilevazioni terrestri, la NASA impiega anche delle tecnologie satellitari avanzate come gli spettrometri per monitorare le variazioni globali di CO_2.
All'interno del dataset le variabili presenti erano due: la media mensile del livello di concentrazione di CO_2 in atmosfera, costruita a partire dalle osservazioni giornaliere, e la media destagionalizzata. Per questa analisi è stata selezionata la prima variabile ("monthly_average") perché rappresenta il dato grezzo, indispensabile per l'identificazione di eventuali cicli stagionali, obiettivo di questo lavoro.
Per quanto riguarda il Livello Medio Globale del Mare (GMSL), i dati sono stati anch'essi ottenuti dal portale NASA "Climate Change: Vital Signs of the Planet" (accessibile tramite il link: https://climate.nasa.gov/vital-signs/sea-level/?intent=121). Questa serie storica è costruita a partire da osservazioni satellitari di altimetria a partire dal 1993, questi dati sono cioè ottenuti misurando l'altezza della superficie del mare rispetto al centro della terra. Il dataset contiene un numero di osservazioni mensili che è variabile e che va dalle 2 alle 4, per questa ragione è stato necessario applicare un aggregazione delle rilevazioni tramite l'uso della media aritmetica, in modo tale da ottenere una frequenza mensile.

L'uso delle osservazioni satellitari è un metodo innovativo, che ha sostituito quello basato sulle registrazioni dei mareografi costieri, in uso fino ai primi anni '90.
Le variabili osservate, tutte espresse in millimetri (mm), presentano diverse elaborazioni per facilitare l'analisi. Si distinguono principalmente in: serie grezza (gmsl_no_gia), serie a cui è stata già applicata una correzione per l'aggiustamento isostatico glaciale (GIA), serie sottoposte a tecniche di smoothing e serie che combinano smoothing e destagionalizzazione.
Per l'analisi della serie storica sul livello del mare è stato scelto di analizzare la variabile "gmsl_gia", ovvero la serie corretta tenendo conto del fatto che la crosta terrestre è ancora in lento movimento e questo altera il volume dei bacini oceanici. Infatti, lo scioglimento delle massicce calotte glaciali che 20000 anni fa ricoprivano parte del globo terrestre, ha portato e sta tuttora portando la terra e il fondale a sprofondare o sollevarsi, influenzando le misurazioni del livello del mare. Appare dunque evidente come la correzione GIA, stimata in circa - 0.3 mm/anno, sia fondamentale per isolare i cambiamenti del livello del mare dovuti a fenomeni attuali (come ad esempio espansione termica dell'acqua e fusione dei ghiacci contemporanei), separandoli dalla continua deformazione geologica del pianeta.
La variabile utilizzata è quindi la variazione del livello del mare corretta e riferita ad una baseline, che in questo caso è stata la media del GMSL durante il ventennio 1996-2016. Questo spiega perchè vi siano alcune osservazioni negative all'interno della serie: il minimo è -43.36 mm, mentre il massimo valore è 83.85 mm.

L'ultimo obiettivo di questa tesi, dopo aver modellizzato singolarmente le due serie storiche, è quello di condurre un'analisi congiunta delle due. Per poterlo fare è stato necessario creare un unico dataset, in cui le date fossero allineate ed uniformate (tabella 3.1). A tal fine, in entrambi i dataset è stata introdotta una variabile comune denominata "year_month" (contenente mese e anno dell'osservazione). Successivamente, è stato creato un dataframe unificato tramite il comando inner_join utilizzando come chiave la colonna temporale comune. Il dataset risultante risulta temporalmente allineato, con un periodo di osservazione basato sulle date coperte dal GMSL, che parte dal 1993. Di conseguenza il nuovo dataset ha 384 osservazioni, 420 in meno di quelle contenute nel dataset sul livello della CO_2.

year_month	*co2_monthly*	*gmsl_gia*
1993-01	357.10	- 41.005
1993-02	357.42	- 39.233
	…	
2025-01	426.65	71.310
2025-02	427.09	69.915

Tabella 3.1: dataset unificato contenente entrambi le serie storiche (1993 - 2025)

3.3 EDA

L'Analisi Esplorativa dei Dati (EDA) rappresenta una fase cruciale nella modellazione delle serie storiche in quanto consente di acquisire una comprensione approfondita di alcune delle caratteristiche intrinseche dei dati, prima di andare ad applicare modelli complessi. Una volta verificata l'assenza di dati mancanti, lo scopo principale di questa fase è quello di visualizzare e riassumere le proprietà chiave delle serie temporali come la stazionarietà, la stagionalità e la presenza di trend o cicli. In questo modo i grafici possono fornirci un'intuizione grafica delle trasformazioni da applicare per rendere i dati idonei alla modellazione.

3.3.1 Visualizzazione delle serie originali individualmente e congiuntamente

L'analisi visiva della serie storica della concentrazione di CO_2 (grafico 3.1) evidenzia immediatamente un trend di crescita costante nel corso dell'intero periodo di osservazione, indicando un aumento costante del livello di CO_2 nell'atmosfera con una concentrazione oggi pari a 420 ppm, contrariamente ai 320 ppm di inizio rilevazione.

Parallelamente a questo trend di lungo periodo, è possibile notare un oscillazione regolare all'interno di ogni anno, sintomo della presenza di stagionalità. La presenza di questo trend e di questa ciclicità rendono la serie non stazionaria e richiedono delle trasformazioni, in modo tale da poterla modellare.

Infine non vi sono osservazioni anomale o interruzioni significative nei pattern evidenziati, confermando la regolarità della serie.

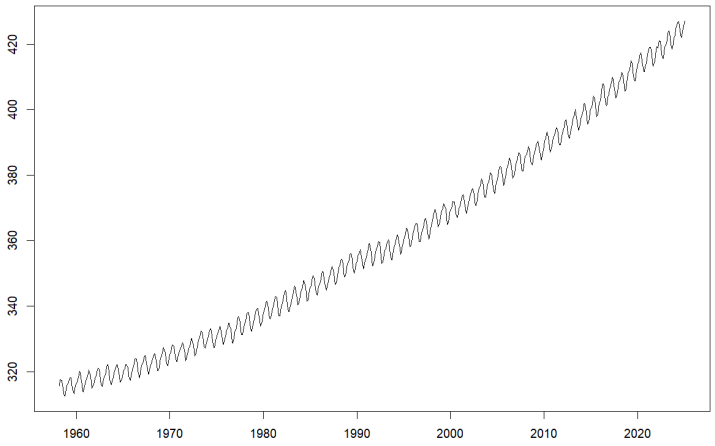

Grafico 3.1: serie storica della concentrazione di CO_2 (1958 - 2025)

Analizzando invece l'andamento storico del Livello Medio Globale del Mare per il periodo 1993-2025 (grafico 3.2) è possibile osservare anche in questo caso un trend di crescita ascendente nel corso di tutto il periodo di osservazione. Fino al 2010 la crescita sembra essere quasi lineare, ma dopo quest'anno sembra subire accelerazioni abbastanza evidenti.

Anche in questo caso è possibile notare delle fluttuazioni regolari attorno al trend centrale, associabili ad una componente stagionale. Non si rilevano anomalie o discontinuità.

Infine è possibile affermare che la presenza di questo trend rende non stazionaria la serie del GMSL, che necessita anch'essa dunque di trasformazioni prima di poter essere modellizzata.

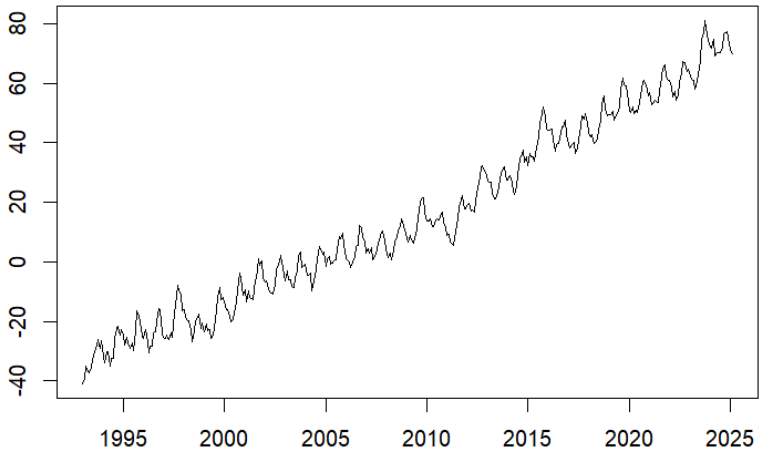

Grafico 3.2: Serie storica del livello medio globale del mare (1993 - 2025)

Dopo aver esaminato le dinamiche individuali delle due serie originali, è fondamentale comprendere la loro relazione congiunta per identificare eventuali movimenti o tendenze comuni. Il grafico 3.3 presenta uno scatterplot che permette di visualizzare la relazione tra la

concentrazione di CO_2 (asse X) e il GMSL (asse y). Da esso emerge chiaramente una correlazione positiva tra le variabili ed un forte trend di crescita in entrambe le serie.

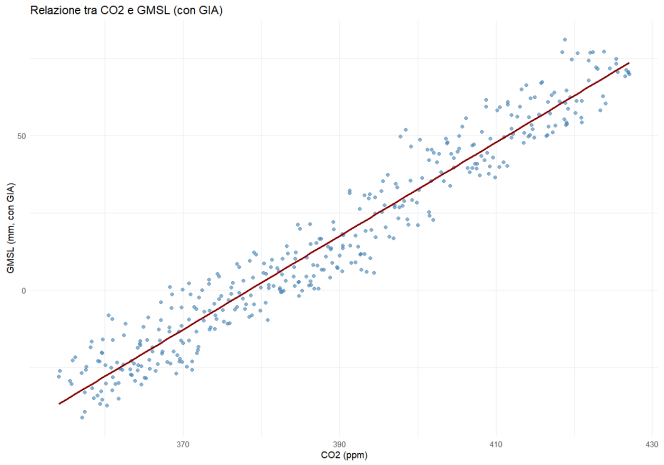

Grafico 3.3: scatterplot tra CO_2 e GMSL

3.3.2 Analisi della stazionarietà e della stagionalità della concentrazione di CO_2

Dopo aver osservato l'andamento delle serie originali e aver constatato l'assenza di stazionarietà, è necessario applicare delle trasformazioni e visualizzare gli effetti che queste hanno su alcuni appositi grafici diagnostici.

Nel caso della serie sulla concentrazione di CO_2 nell'atmosfera, è stata inizialmente applicata una differenziazione al primo ordine, con l'obiettivo di eliminare il trend presente.

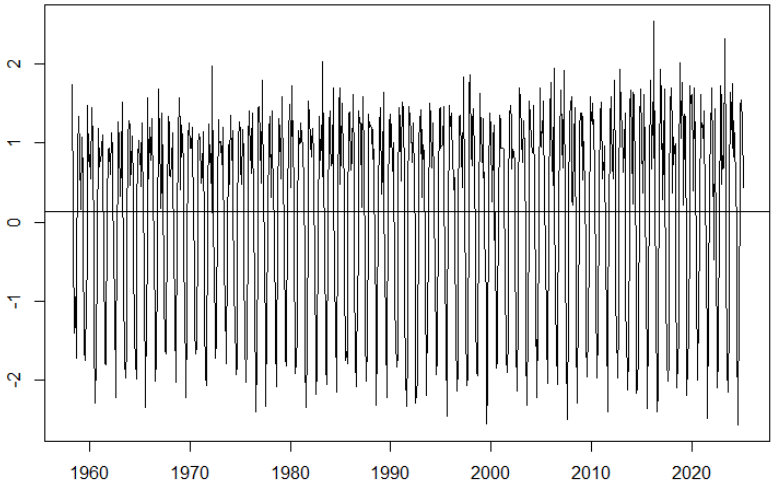

Grafico 3.4: serie differenziata della concentrazione di CO_2

Il risultato (grafico 3.4) è stato parzialmente soddisfacente perchè è riuscito nell'intento di eliminare il trend, ma presentava ancora un comportamento troppo variabile, da ricondurre

presumibilmente ad una stagionalità. Per verificare tale ipotesi abbiamo costruito un correlogramma (grafico 3.5a) ed un seasonal plot (grafico 3.5b).

Il primo grafico presenta nella sezione dell'ACF dei picchi molto marcati in corrispondenza dei lag multipli di 12, indicatore chiaro di una forte e persistente componente stagionale. Questa ipotesi trova ulteriore conferma nel seasonal plot (grafico 3.4b) che presenta una struttura a forma di "U" con valori minimi in corrispondenza dei mesi di aprile, maggio e giugno con poi dei massimi stagionali da ottobre a gennaio.

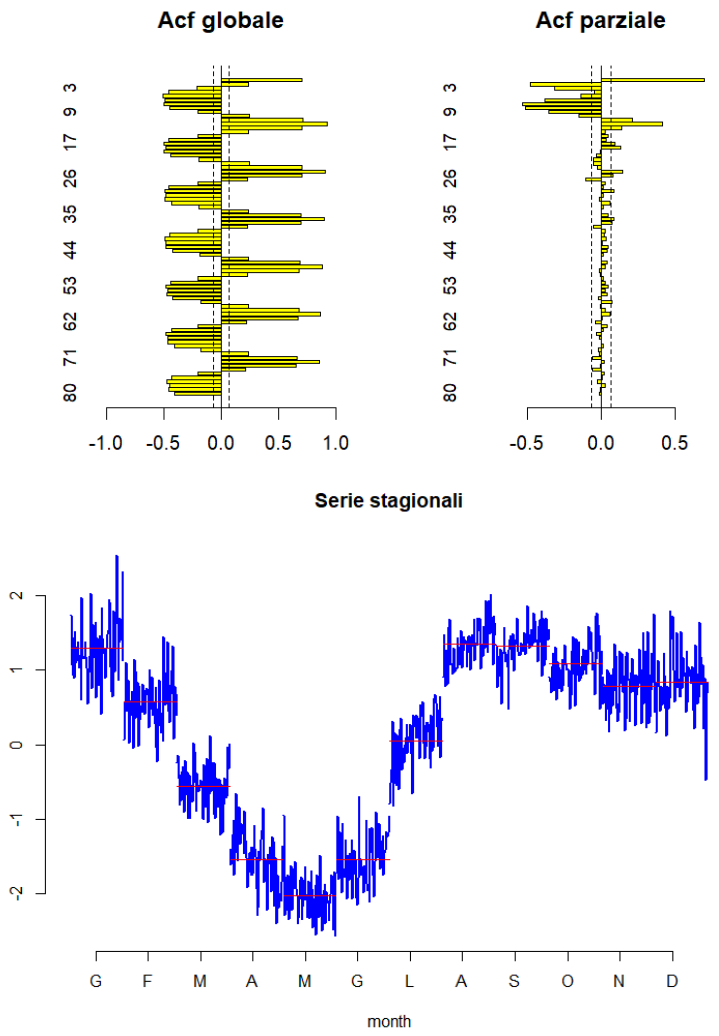

Grafico 3.5a - 3.5 b: Correlogramma e seasonal plot dopo differenziazione prima

Una volta evidenziata la presenza di stagionalità all'interno della serie differenziata si è resa necessaria la ricerca di un metodo efficace per eliminarla e si è scelto di applicare una differenziazione di ordine 12, andando ad ottenere una serie come quella visualizzabile nel grafico 3.6, dove le fluttuazioni stagionali risultano ora assenti e la variazione media risulta essere prossima allo 0, sintomo di stazionarietà.

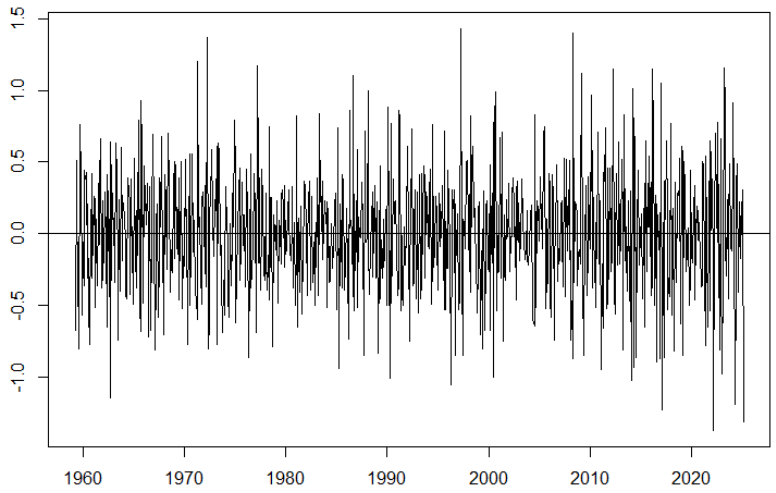

Grafico 3.6: andamento della serie con differenza 1 e differenza 12

Per verificare la reale efficacia delle trasformazioni, sono stati analizzati nuovamente il correlogramma (grafico 3.7a) ed il seasonal plot (grafico 3.7b). A giudicare da questi due grafici emerge che la serie, a seguito delle differenziazioni, risulta essere stazionaria sia in media che in varianza: i correlogrammi sia della acf che della pacf mostrano autocorrelazioni contenute nelle bande e la media stagionale risulta ora essere allineata durante il corso di tutti i mesi dell'anno.

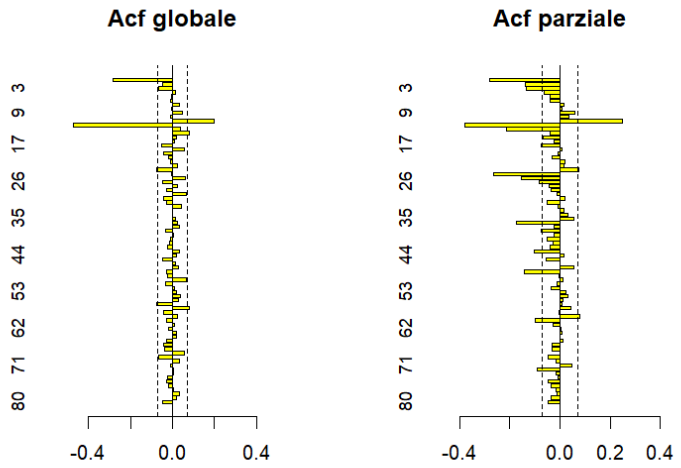

Grafico 3.7a: Correlogramma dopo la differenziazione stagionale

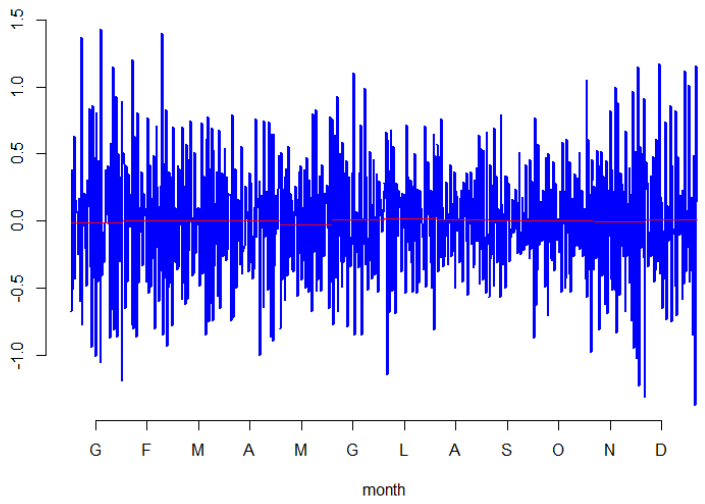

Grafico 3.7b: seasonal plot dopo la differenziazione stagionale

Per effettuare un'ulteriore verifica statistica della stazionarietà è stato applicato l'Augmented Dickey Fuller test - ADF (Dickey & Fuller, 1979). L'esito del test ha confermato l'evidenza grafica: avendo ottenuto un p-value <0.01, inferiore alla soglia del 5%, è stata rifiutata l'ipotesi nulla di non stazionarietà. Pertanto si conclude che la serie, a seguito delle trasformazioni applicate, è ora considerabile stazionaria.

3.3.3 Analisi della stazionarietà e della stagionalità della concentrazione di GMSL

Risolta la problematica della stazionarietà per la serie relativa alla concentrazione atmosferica di CO_2, si è passati ad analizzare la serie sul livello medio globale del mare, applicando una procedura simile volta a verificarne la stazionarietà.

Il primo passaggio è stato applicare una differenziazione prima per rimuovere il trend che caratterizzava anche la serie sul GMSL. La serie, una volta trasformata, è stata visibilmente privata del trend e fluttua attorno ad una media prossima allo zero (grafico 3.8).

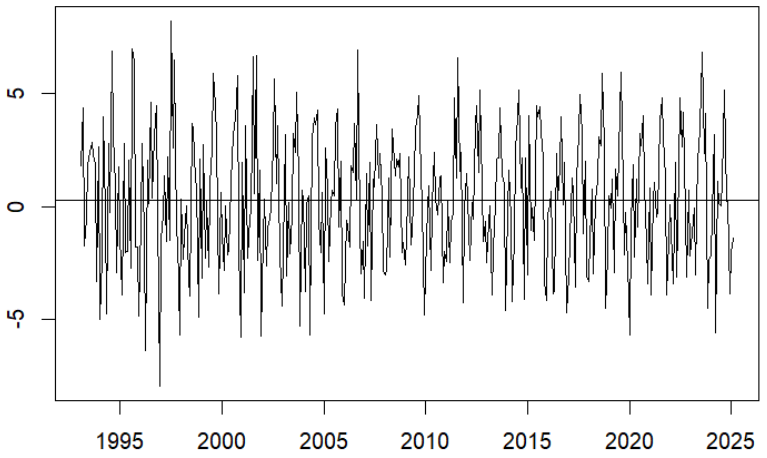

Grafico 3.8: serie differenziata del GMSL

Per quanto riguarda la variabilità della serie, l'ampiezza delle oscillazioni sembra essere relativamente costante nel tempo, ma per averne una conferma ulteriore sono stati analizzati il correlogramma (grafico 3.9a) ed il seasonal plot (grafico 3.9b). Dalle verifiche effettuate su entrambi i plot è emersa la presenza di una stagionalità residua: l'ACF presenta picchi significativi ai lag multipli di 12 e la media nel seasonal plot non è allineata.

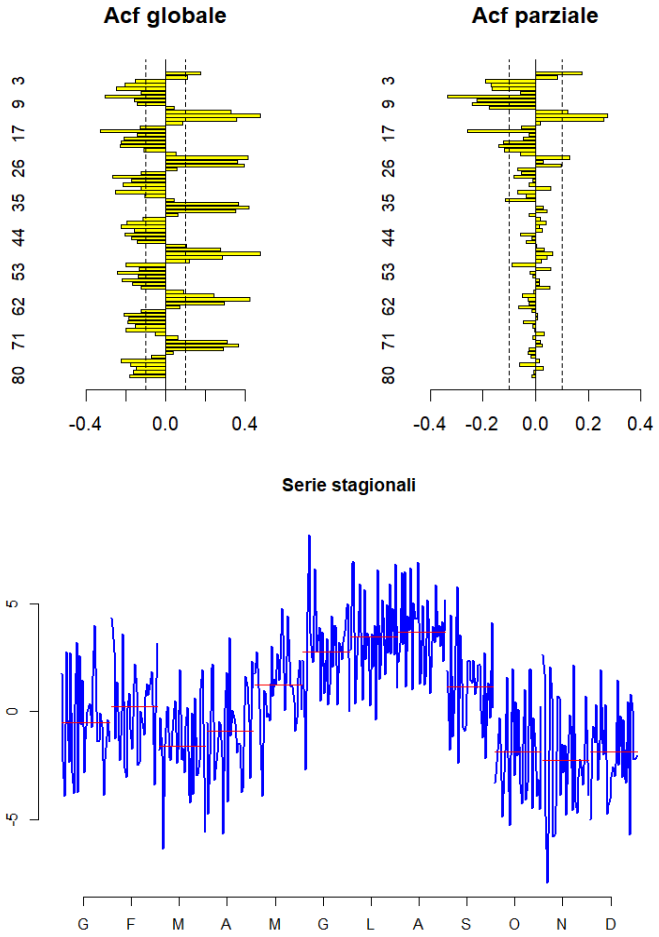

Grafico 3.9a - 3.9b: correlogramma e seasonal plot della serie dopo differenziazione prima

Seguendo un approccio analogo a quello adottato per la serie precedente, anche in questo caso la componente stagionale è stata trattata mediante una differenziazione di ordine 12, ottenendo fluttuazioni più stabili e distribuite perfettamente intorno allo 0 (grafico 3.10).

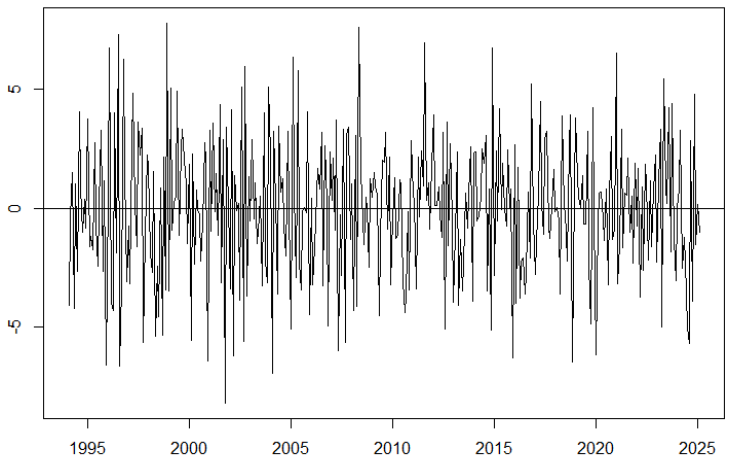

Grafico 3.10: serie GMSL dopo la differenziazione stagionale

Analogamente al percorso seguito nel corso dell'analisi della serie sulla CO_2, sono stati esaminati anche per la GMSL il correlogramma (grafico 3.11a) ed il seasonal plot (grafico 3.11b). Entrambi gli strumenti si sono rivelati utili a confermare l'efficace rimozione della componente stagionale, rendendo stazionaria la serie. Dal correlogramma è possibile osservare un decadimento, seppur lento, dell'ACF in corrispondenza dei lag multipli di 12, accompagnato dallo spegnimento della PACF. Inoltre anche il seasonal plot risulta avere un comportamento stazionario avendo la media mensile pressoché allineata nel corso dell'anno.

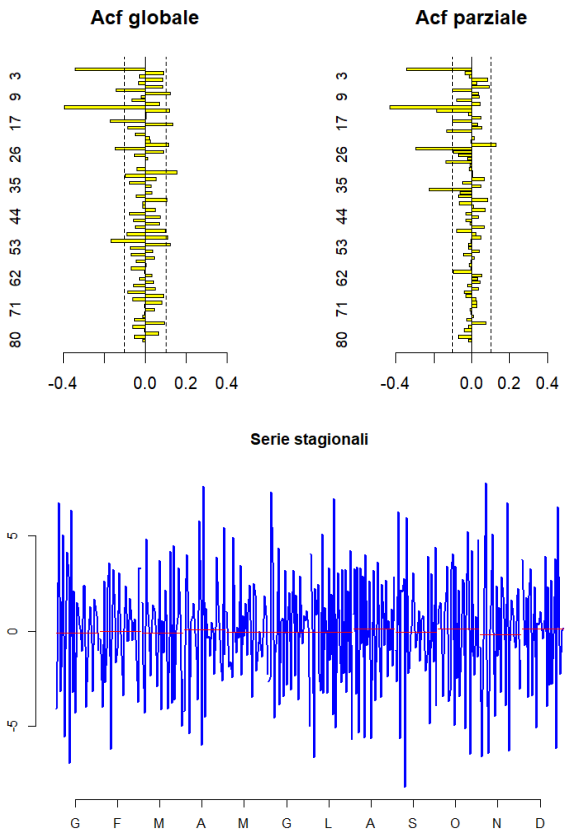

Grafici 3.11a - 3.11b: Correlogramma e seasonal plot dopo la differenziazione stagionale

A supporto dell'evidenza grafica è stato applicato l'ADF alla serie GMSL trasformata. Anche in questo caso il valore del p-value è risultato inferiore a 0.01, minore dunque della soglia fissata al 5%. Questo ha permesso di rifiutare l'ipotesi nulla di non stazionarietà e di affermare dunque che la serie risulti essere stazionaria ed idonea alla modellizzazione.

3.4 Decomposizione delle serie storiche e analisi delle componenti classiche

Per concludere la fase di analisi esplorativa di una serie storica, una volta soddisfatta la richiesta di stazionarietà, è necessario comprendere le forze che compongono la serie storica.
Per fare ciò, è stato adottato un modello di decomposizione additivo dove le componenti dell'analisi classica (trend, stagionalità, ciclo, componente accidentale) vengono tra loro sommate. La scelta di questo metodo, a discapito di quello moltiplicativo, risiede nel fatto che l'ampiezza delle fluttuazioni stagionali appare essere, in entrambi i casi, costante nel tempo, indipendentemente dal livello crescente del trend.

3.4.1 Decomposizione della CO_2

Per effettuare la decomposizione della serie è stata utilizzata la funzione "decompose" del pacchetto tseries, che consente di separare le diverse componenti additive, ottenendo una rappresentazione esplicita delle dinamiche che contribuiscono all'andamento della serie (grafico 3.12).

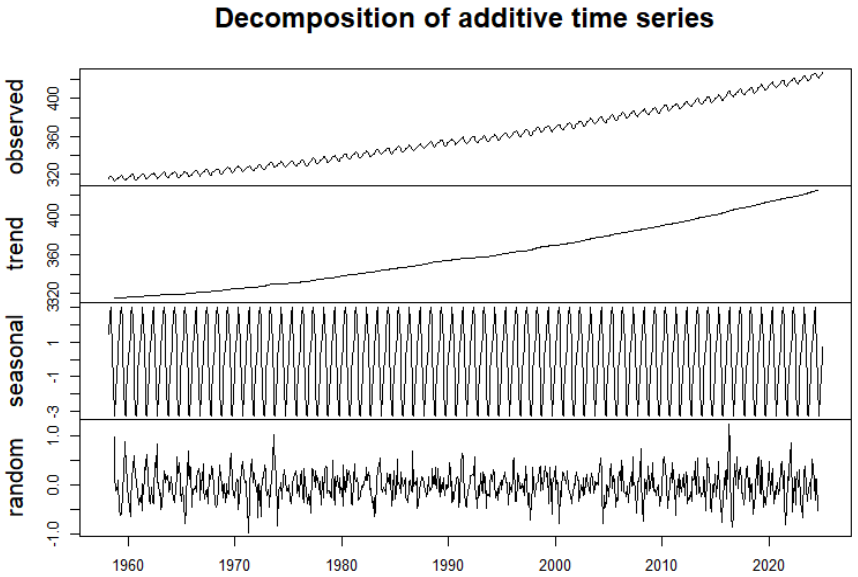

Grafico 3.12: Decomposizione additiva della serie CO_2

Si procede ora alla descrizione delle singole componenti ottenute dalla decomposizione:

- componente di trend: viene evidenziata una crescita costante della CO2 atmosferica nel tempo, compatibile con un aumento delle emissioni antropiche di gas serra.
- componente stagionale: nel pannello che mostra l'oscillazione sistematica che si ripete annualmente è possibile osservare picchi e cavi regolari. L'ampiezza è pressochè costante nel tempo e per questo la componente stagionale sembra essere stabile, con una periodicità annuale. Una spiegazione plausibile alla regolarità che caratterizza la componente stagionale della serie è il ciclo biologico delle piante, dal momento che in estate vi è un maggiore assorbimento della CO_2 di quanto ce ne sia in inverno e per questo i livelli in inverno sembrano essere più alti come teorizzato in "The Carbon cycle" (Riebeek, 2011).
- componente accidentale: questa componente rappresenta ciò che resta della serie una volta rimosse le altre componenti, cioè gli scostamenti irregolari e non spiegati legati a variabilità imprevedibili. Questa componente residua presenta valori centrati intorno allo 0 con alcuni picchi molto contenuti.

3.4.2 Decomposizione del GMSL

Una volta completata la decomposizione della serie relativa alla concentrazione atmosferica di CO_2, si applica lo stesso modello additivo alla serie del GMSL al fine di analizzarne le componenti scomposte.

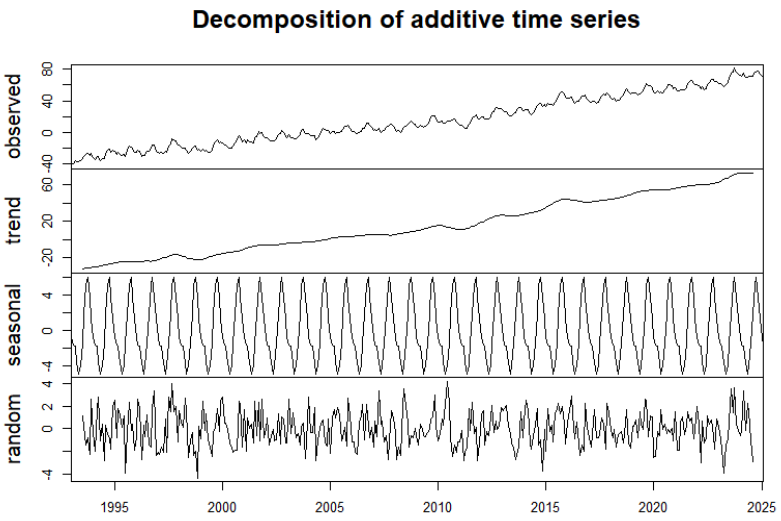

Grafico 3.13: Decomposizione additiva della serie del GMSL

A partire dal grafico 3.13 è possibile analizzare separatamente le componenti che costituiscono la serie:

- il trend (componente di tendenza) è crescente e abbastanza lineare, con alcune flessioni o accelerazioni in alcune fasi.
- la componente stagionale anche in questo caso risulta essere molto pronunciata ma al tempo stesso stabile, con le oscillazioni che hanno la stessa ampiezza. La componente stagionale ha una periodicità annuale e vede dei picchi nel corso dei mesi di settembre, ottobre e novembre, mentre i picchi sono osservati da febbraio ad aprile. Questo fenomeno è dovuto all'espansione termica degli oceani nei mesi più caldi e all'impatto ritardato della fusione glaciale. (IPCC, 2021)
- la componente accidentale presenta un'ampiezza contenuta, distribuita uniformemente intorno allo 0 lungo la serie, con alcuni picchi leggermente più pronunciati rispetto a quelli della serie precedente, ma pur sempre accettabili.

CAPITOLO 4 - Modellizzazione e Previsione

4.1 Introduzione ed Obiettivi

Nel presente capitolo viene affrontata la modellizzazione quantitativa delle serie storiche relative alla concentrazione atmosferica di CO_2 e al GMSL. L'analisi si articola in due parti: una prima fase dove viene effettuata una modellizzazione univariata di entrambe le serie ed una seconda fase di analisi congiunta, dove si valutano relazioni dinamiche e causali tra le due variabili tramite appositi modelli. In entrambe le fasi l'obiettivo principale è quello di cercare di giungere a previsioni che siano attendibili il più possibile, in modo da comprendere le potenziali interconnessioni tra le serie, la loro evoluzione e le implicazioni che questo andamento evolutivo potrebbe avere da un punto di vista ambientale.

Per la modellizzazione univariata è stato scelto di adottare la procedura Box-Jenkins per la ricerca del modello che meglio descriva l'andamento della serie. Questo metodo si compone di 5 differenti fasi, 3 delle quali sono state svolte all'interno del precedente capitolo (analisi grafica, rendere stazionaria la serie e analisi dei correlogrammi). Le rimanenti fasi verranno qui svolte per entrambe le serie storiche e comprendono la stima del modello e diagnostica dei residui ed infine la previsione.

Nella seconda parte di questo capitolo si procederà ad effettuare un'analisi esplorativa dedicata alla verifica della causalità (e le eventuali direzioni di causalità) e della cointegrazione tra le serie. Comprendere la natura della relazione tra le due serie si rivelerà utile per comprendere i risultati derivanti dall'applicazione di modelli VAR (Vector AutoRegressive), con lo scopo di analizzare le dinamiche congiunte e quelli legati al modello ECM (Error Correction Model), per cogliere eventuali relazioni di equilibrio a lungo periodo tra CO_2 e GMSL. Infine si procederà all'applicazione del modello ARDL, in cui i livelli presenti e futuri di una delle due serie sono considerati dipendenti dai propri lag e da quelli dell'altra serie storica.

In questa analisi, per la modellizzazione univariata delle serie storiche, sono state utilizzate alcune funzioni personalizzate sviluppate appositamente dal professor Andrea Marletta nel corso di Scienze Statistiche ed Economiche. Tra queste, la funzione arimaest consente di stimare modelli ARIMA/SARIMA in modo efficiente, mentre la funzione forecastplott facilita la rappresentazione grafica delle previsioni prodotte, includendo anche riferimenti temporali espliciti per una corretta interpretazione. A supporto della diagnostica sono state

inoltre sviluppate le funzioni testnorm per la verifica della normalità dei residui e correlresidui per valutarne l'incorrelazione, elementi fondamentali per valutare la bontà dei modelli stimati. Per quanto riguarda l'analisi multivariata, invece, sono state utilizzate funzioni di librerie consolidate nell'ambito delle serie temporali economiche e statistiche quali vars per la stima di modelli VAR e ECM, lmtest per i test di causalità di Granger e dynlm per il modello ARDL. Alcune visualizzazioni esplorative sono state realizzate con la libreria ggplot2, che permette di rappresentare efficacemente la relazione tra le serie ambientali CO_2 e GMSL.

4.2 Modellizzazione della Serie della concentrazione di CO_2

Nel capitolo precedente la serie è stata resa stazionaria mediante una differenziazione prima, che ha rimosso il trend di lungo periodo, e una differenziazione stagionale di ordine dodici, che ha eliminato l'effetto irregolare dovuto alla stagionalità. A questo punto la serie può essere considerata stazionaria e quindi modellizzabile tramite modelli SARIMA (Box & Jenkins, 1976), data la presenza di stagionalità nella serie originale.

La quarta fase della procedura di Box-Jenkins prevede l'identificazione del modello più appropriato, valutandone le prestazioni in termini di significatività dei coefficienti e di Akaike Information Criterion - AIC (Akaike, 1974). A tale scopo sono state testate diverse combinazioni di componenti autoregressive e a media mobile, sia nella parte stagionale che in quella non stagionale. La selezione è stata condotta inizialmente scartando i modelli con coefficienti non significativi (ossia con t-statistics < |2|). Tra i modelli rimanenti, la scelta definitiva è stata guidata dal valore minimo dell'AIC. Successivamente è stata verificata anche l'eventuale utilità dell'inclusione di una costante nel modello, valutandone l'impatto sulle performance complessive. Gli output riportati di seguito riguardano unicamente i modelli con coefficienti significativi, che hanno costituito le reali alternative nella selezione finale.

La prima combinazione testata è stata il modello SARIMA(0,1,1)x(1,1,1), al fine di valutare la configurazione della componente stagionale. È risultato subito evidente che la parte autoregressiva stagionale non fosse significativa e quindi non dovesse essere inclusa. Successivamente è stato considerato un modello misto nella parte non stagionale e con sola componente a media mobile in quella stagionale, ossia il SARIMA(1,1,1)x(0,1,1). Tutti i coefficienti di questo modello sono risultati significativi, rendendolo un candidato valido, pur lasciando spazio alla valutazione di ulteriori configurazioni.

Dopo diversi tentativi, è emerso che la componente stagionale a media mobile non dovesse superare un ritardo, poiché l'aggiunta di ulteriori lag non apportava benefici al modello. Le due configurazioni non stagionali ritenute più promettenti sono risultate:

- un modello misto con entrambe le componenti (AIC = 439.45);
- un modello con due componenti a media mobile (AIC = 440.61).

A giudicare dal valore dell'AIC, il primo dei due si è dimostrato più appropriato. In entrambi i casi, l'introduzione di una costante ha migliorato le prestazioni di entrambi, riducendo ulteriormente l'AIC e risultando significativa. In particolare, per il modello SARIMA(1,1,1)x(0,1,1) l'intercetta ha ridotto l'AIC a 432.27, risultando ancora una volta il modello migliore in quanto l'AIC ha valore inferiore a quello del modello alternativo SARIMA(0,1,2)x(0,1,1) (=434.45), come si può osservare nelle figure 4.1a e 4.1b.

```
Call:
arima(x = dati, order = nsorder, seasonal = list(order = sorder, period = periodo),
    include.mean = vf)

Coefficients:
         ar1      ma1     sma1  intercept
      0.2742  -0.6339  -0.8839     0.0025
s.e.  0.0844   0.0682   0.0172     0.0007

sigma^2 estimated as 0.09755:  log likelihood = -211.14,  aic = 432.27

$tstatistics
       ar1        ma1       sma1  intercept
  3.249648  -9.288501 -51.411522   3.350408
```

```
Call:
arima(x = dati, order = nsorder, seasonal = list(order = sorder, period = periodo),
    include.mean = vf)

Coefficients:
          ma1      ma2     sma1  intercept
      -0.3717  -0.0909  -0.8809     0.0025
s.e.   0.0351   0.0351   0.0171     0.0008

sigma^2 estimated as 0.09786:  log likelihood = -212.22,  aic = 434.45

$tstatistics
       ma1        ma2       sma1  intercept
-10.584964  -2.590620 -51.400614   3.071225
```

Figura 4.1a- 4.1b: output dei due modelli SARIMA stimati, sopra SARIMA(1,1,1)x(0,1,1), sotto SARIMA(0,1,2)x(0,1,1)

Individuata la configurazione SARIMA più performante, si è proceduto alla verifica della normalità e dell'incorrelazione dei residui, come previsto dalla procedura di Box-Jenkins. Qualora tali proprietà non fossero state rispettate, l'analisi sarebbe stata ripetuta considerando il secondo miglior modello identificato nella fase precedente.

A tal fine sono stati applicati diversi strumenti di analisi dei residui. In primo luogo, la normalità è stata verificata mediante il test di Jarque-Bera (Jarque & Bera, 1980), supportato dall'analisi visiva dell'istogramma dei residui. Successivamente è stata valutata l'assenza di autocorrelazione, utilizzando sia il test di Ljung-Box (Ljung & Box, 1978) sia l'analisi del correlogramma (ACF). L'impiego congiunto di queste verifiche consente di accertare se i

residui possano essere considerati assimilabili a rumore bianco e, di conseguenza, se il modello stimato sia in grado di descrivere in maniera adeguata la dinamica della serie storica. Per quanto riguarda la normalità, il test di Jarque-Bera ha restituito un p-value pari a 0.028, valore che porterebbe a rifiutare l'ipotesi nulla di normalità ad un livello di significatività del 5%, ma andando a guardare l'istogramma dei residui (figura 4.2) si può osservare una distribuzione sostanzialmente simmetrica, con media pari a 0 ma con una leggera asimmetria sulle code. Nel complesso quindi, pur non potendo affermare una perfetta normalità, la distribuzione dei residui è risultata accettabile ai fini dell'analisi, in linea con quanto spesso riscontrato nei modelli SARIMA applicati a dati reali.

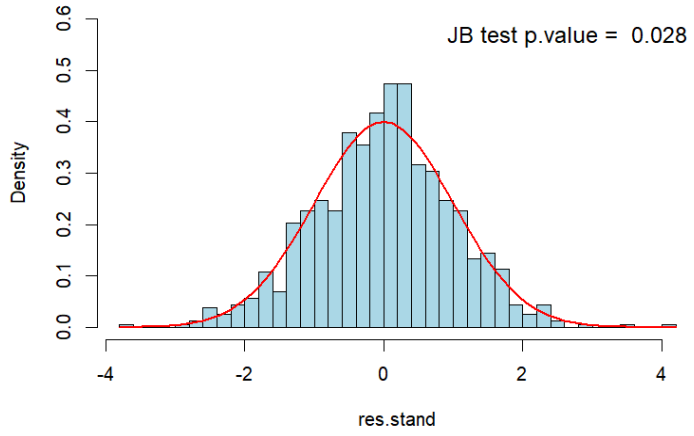

Figura 4.2: Istogramma dei residui e test di Jarque-Bera

Nel corso della verifica dell'incorrelazione dei residui è stato considerato il correlogramma dei residui (figura 4.3), dove le funzioni di correlazione ed autocorrelazione non hanno evidenziato strutture residue significative, con la maggior parte dei valori compresi entro le bande di confidenza e solo pochi picchi isolati. Analogamente, i p-value del test di Ljung-Box sono risultati ampiamente superiori alla soglia del 5% per la maggior parte dei lag considerati, escludendo la presenza di autocorrelazioni sistematiche. È quindi possibile concludere che il modello SARIMA selezionato abbia rappresentato adeguatamente la dinamica della serie analizzata, soddisfando le condizioni richieste dalla procedura di Box-Jenkins.

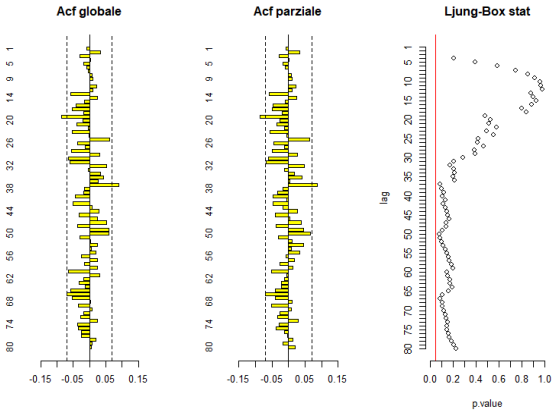

Figura 4.3: correlogramma dei residui e p-value del test di Ljung-Box

Verificato che il modello soddisfi i requisiti previsti dalla procedura, si può procedere all'ultimo step della procedura di Box-Jenkins: la previsione dei valori futuri. Le previsioni ottenute vengono qui riportate in forma puntuale negli output numerici (figura 4.4), mentre nella rappresentazione grafica i valori stimati sono inseriti nelle bande di confidenza che delimitano l'intervallo di variabilità atteso delle stime. L'introduzione delle bande di confidenza consente di valutare non solo l'evoluzione puntuale della variabile. ma anche il grado di incertezza associato alle proiezioni. Le previsioni di seguito riportate mostrano valori espressi in ppm e si estendono fino alla fine del 2050.

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
2025			427.9018	429.4430	430.1068	429.6424	427.8285	425.7257	424.4380	424.6831	426.2430	427.6979
2026	428.8863	429.7796	430.4591	431.9701	432.6271	432.1612	430.3469	428.2440	426.9563	427.2014	428.7613	430.2162
2027	431.4046	432.2979	432.9774	434.4885	435.1454	434.6795	432.8652	430.7624	429.4746	429.7197	431.2796	432.7345
2028	433.9230	434.8162	435.4957	437.0068	437.6637	437.1979	435.3835	433.2807	431.9930	432.2381	433.7980	435.2529
2029	436.4413	437.3346	438.0140	439.5251	440.1821	439.7162	437.9019	435.7990	434.5113	434.7564	436.3163	437.7712
2030	438.9596	439.8529	440.5324	442.0434	442.7004	442.2345	440.4202	438.3173	437.0296	437.2747	438.8346	440.2895
2031	441.4779	442.3712	443.0507	444.5617	445.2187	444.7528	442.9385	440.8357	439.5479	439.7930	441.3529	442.8078
2032	443.9962	444.8895	445.5690	447.0801	447.7370	447.2712	445.4568	443.3540	442.0663	442.3114	443.8713	445.3261
2033	446.5146	447.4079	448.0873	449.5984	450.2553	449.7895	447.9751	445.8723	444.5846	444.8297	446.3896	447.8445
2034	449.0329	449.9262	450.6056	452.1167	452.7737	452.3078	450.4935	448.3906	447.1029	447.3480	448.9079	450.3628
2035	451.5512	452.4445	453.1240	454.6350	455.2920	454.8261	453.0118	450.9089	449.6212	449.8663	451.4262	452.8811
2036	454.0695	454.9628	455.6423	457.1534	457.8103	457.3444	455.5301	453.4273	452.1395	452.3846	453.9445	455.3994
2037	456.5878	457.4811	458.1606	459.6717	460.3286	459.8628	458.0484	455.9456	454.6579	454.9030	456.4629	457.9178
2038	459.1062	459.9995	460.6789	462.1900	462.8470	462.3811	460.5667	458.4639	457.1762	457.4213	458.9812	460.4361
2039	461.6245	462.5178	463.1973	464.7083	465.3653	464.8994	463.0851	460.9822	459.6945	459.9396	461.4995	462.9544
2040	464.1428	465.0361	465.7156	467.2266	467.8836	467.4177	465.6034	463.5006	462.2128	462.4579	464.0178	465.4727
2041	466.6611	467.5544	468.2339	469.7450	470.4019	469.9361	468.1217	466.0189	464.7311	464.9762	466.5361	467.9910
2042	469.1795	470.0728	470.7522	472.2633	472.9202	472.4544	470.6400	468.5372	467.2495	467.4946	469.0545	470.5094
2043	471.6978	472.5911	473.2705	474.7816	475.4386	474.9727	473.1584	471.0555	469.7678	470.0129	471.5728	473.0277
2044	474.2161	475.1094	475.7889	477.2999	477.9569	477.4910	475.6767	473.5738	472.2861	472.5312	474.0911	475.5460
2045	476.7344	477.6277	478.3072	479.8182	480.4752	480.0093	478.1950	476.0922	474.8044	475.0495	476.6094	478.0643
2046	479.2527	480.1460	480.8255	482.3366	482.9935	482.5277	480.7133	478.6105	477.3228	477.5679	479.1278	480.5826
2047	481.7711	482.6644	483.3438	484.8549	485.5119	485.0460	483.2316	481.1288	479.8411	480.0862	481.6461	483.1010
2048	484.2894	485.1827	485.8621	487.3732	488.0302	487.5643	485.7500	483.6471	482.3594	482.6045	484.1644	485.6193
2049	486.8077	487.7010	488.3805	489.8915	490.5485	490.0826	488.2683	486.1654	484.8777	485.1228	486.6827	488.1376
2050	489.3260	490.2193	490.8988	492.4099	493.0668	492.6009	490.7866	488.6838	487.3960	487.6411	489.2010	490.6559

Figura 4.4: previsioni puntuali del livello di CO_2 mensile ottenute con SARIMA(1,1,1)x(0,1,1) dal 2025 al 2050

Osservandole è possibile osservare come il modello stimi una crescita regolare e continua della concentrazione di CO_2, con un incremento medio annuo di circa 1-2 ppm, che si traduce in aumento di circa 63 ppm dal 2025 al termine del 2050. Si può inoltre notare come il

modello, oltre al trend di lungo periodo, catturi anche la componente stagionale: all'interno di ciascun anno i picchi ricorrono nel periodo primaverile, salvo poi decrescere parzialmente nel corso dei restanti mesi, pur mantenendo un incremento rispetto allo stesso periodo dell'anno precedente. Questa struttura è coerente con quella osservata nei dati storici e questo è dovuto alla struttura del modello SARIMA selezionato. La rappresentazione grafica che segue (figura 4.5) consente di visualizzare in maniera più immediata l'andamento previsto. La linea blu segue l'andamento delle proiezioni puntuali, mentre le bande circostanti i valori entro i quali è plausibile che i valori futuri si collochino con elevata probabilità. Come tipicamente accade nelle analisi previsive, l'ampiezza delle bande aumenta al crescere dell'orizzonte temporale, riflettendo l'aumento dell'incertezza man mano che ci si spinge verso proiezioni più lontane.

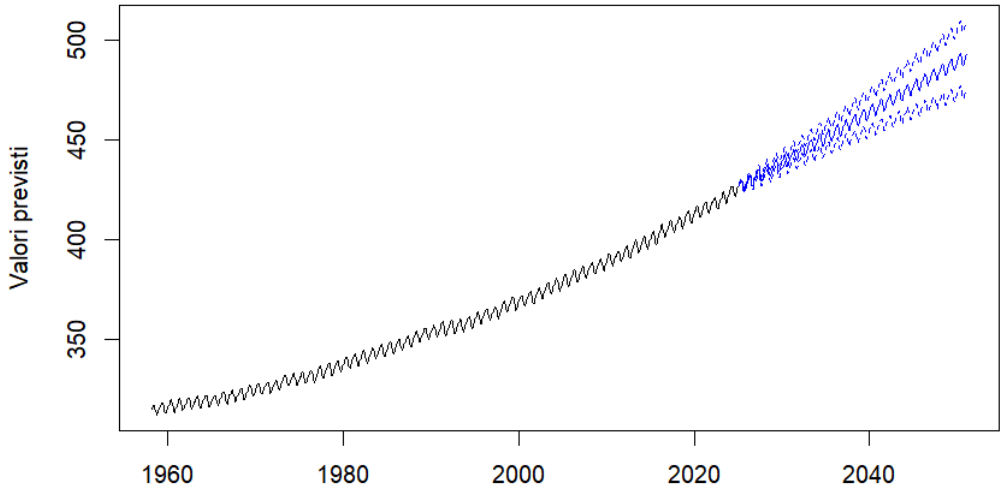

Figura 4.5: forecastplot del livello di CO_2 mensile dal 2025 al 2050

4.3 Modellizzazione della serie del GMSL

Come già fatto in precedenza con la serie relativa alla concentrazione di CO_2, anche nel caso della serie riguardante il GMSL la ricerca del modello ideale è stata attuata a partire dalla serie resa stazionaria nel capitolo precedente tramite le dovute trasformazioni.

Lo studio e la modellizzazione di questa serie sono stati caratterizzati dalla medesima struttura e dagli stessi criteri di quelli applicati nell'analisi della serie dell'anidride carbonica. Infatti, tra i modelli applicati sono stati selezionati ed ulteriormente indagati solamente quelli con i coefficienti significativi (t-statistics < |2|) e, all'interno di questo gruppo ristretto, è stato selezionato come miglior modello quello con l'AIC inferiore.

Nel corso della prima parte della fase di stima si è provato a identificare la miglior configurazione della parte stagionale del modello. Per farlo ci si è basati sulla significatività

dei coefficienti ed è risultato evidente che la combinazione che forniva il miglior trade-off tra significatività ed AIC fosse quella che prevedeva una sola componente a media mobile stagionale: (0,1,1).

In seguito ci si è concentrati sulla parte non stagionale e, dopo aver testato una serie di modelli differenti, sono stati identificati come potenziali candidati ad essere il modello ideale quelli con le seguenti configurazioni:

- un modello con una sola componente autoregressiva non stagionale (AIC = 1606);
- un modello con una sola componente a media mobile non stagionale (AIC = 1603).

Come già fatto in precedenza, anche in questo caso è stata aggiunta ai modelli l'intercetta per valutare che impatto avesse sulle loro performance e, a differenza di quanto avvenuto con la serie storica del livello di CO_2, in questo caso l'output suggeriva di non considerarla dal momento che non era risultata significativa. Di conseguenza la fase di stima del modello può ritenersi conclusa, con la selezione del SARIMA(0,1,1)x(0,1,1) come miglior modello a giudicare dall'AIC che è risultato maggiore di quello del SARIMA(1,1,0)x(0,1,1), come si può notare osservando le figure 4.6a e 4.6b.

```
Call:
arima(x = dati, order = nsorder, seasonal = list(order = sorder, period = periodo),
    include.mean = vf)

Coefficients:
          ar1     sma1
      -0.3596  -1.0000
s.e.   0.0483   0.0357

sigma^2 estimated as 3.82:  log likelihood = -800.09,  aic = 1606.18

$tstatistics
       ar1       sma1
 -7.439578 -28.031070
```

```
Call:
arima(x = dati, order = nsorder, seasonal = list(order = sorder, period = periodo),
    include.mean = vf)

Coefficients:
          ma1     sma1
      -0.3820  -1.0000
s.e.   0.0458   0.0345

sigma^2 estimated as 3.787:  log likelihood = -798.47,  aic = 1602.95

$tstatistics
       ma1       sma1
 -8.343935 -28.984288
```

Figura 4.6a - 4.6b: output dei due modelli SARIMA stimati, sopra SARIMA(1,1,0)x(0,1,1), sotto SARIMA(0,1,1)x(0,1,1)

Identificata la miglior configurazione del modello SARIMA, si è proceduto alla diagnostica dei residui per verificare se potessero essere considerati assimilabili a rumore bianco, indice del fatto che il modello fosse ben funzionante. In caso contrario, si sarebbe presa in considerazione la seconda miglior configurazione del modello.

Per svolgere la diagnostica, come fatto in precedenza, ci si è avvalsi della visualizzazione dell'istogramma e dei correlogrammi dei residui, affiancati da due test statistici: Jarque-Bera e Ljung-Box.

Nel caso del SARIMA(0,1,1)x(0,1,1), nonostante i residui sono risultati fortemente distribuiti come una normale standard (figura 4.7a), si sono verificati dei problemi nell'analisi della loro incorrelazione. Infatti, considerando i primi 80 lag, si può osservare nella figura 4.7b come i p-value delle osservazioni di questi istanti temporali siano dentro la banda limitata dalla linea rossa in corrispondenza ad $\alpha = 5\%$, questo è dovuto ad una correlazione residua al loro interno.

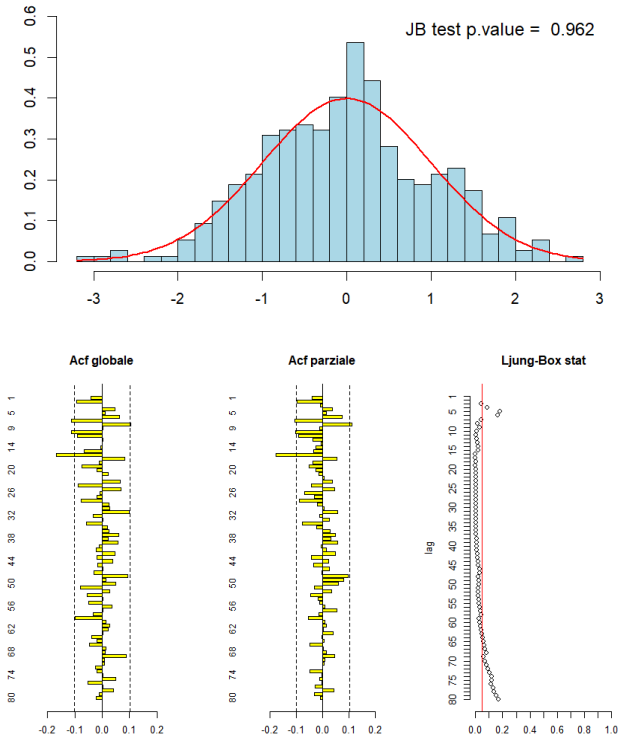

Figura 4.7a - 4.7b: istogramma e test di Jarque-Bera (sopra), correlogramma (sotto) dei residui e test di Ljung-Box del SARIMA(0,1,1)x(0,1,1)

Vista la mancata verifica delle ipotesi diagnostiche riguardanti i residui del modello SARIMA(0,1,1)x(0,1,1), si è optato per l'analisi dei residui di quello che era stato identificato come il secondo miglior modello, ovvero SARIMA(1,1,0)x(0,1,1). Anche in questo caso però, nonostante l'esito positivo del test sulla normalità, non ha restituito l'esito sperato il test di Ljung-Box, con un incorrelazione ancora una volta assente nelle prime 80 osservazioni (figura 4.8).

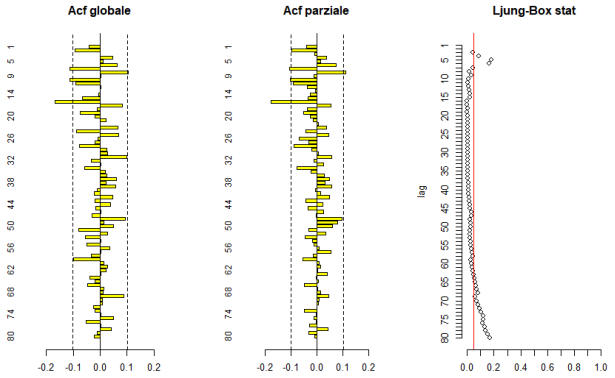

Figura 4.8: correlogramma dei residui e test di Ljung-Box del SARIMA(1,1,0)x(0,1,1)

Per questa ragione è stato deciso di provare ad analizzare il dataset escludendo i primi 4 anni di rilevazioni, considerati degli outlier e potenzialmente dannosi all'analisi. Come avvenuto in precedenza, la configurazione della componente stagionale identificata come ottimale dal processo di selezione prevedeva una sola componente a media mobile. Inoltre le componenti non stagionali più performanti sono risultate essere le stesse di prima: quella con una componente autoregressiva e quella con una componente a media mobile, dando vita cioè ai modelli con le seguenti combinazioni: SARIMA(1,1,0)x(0,1,1) e SARIMA(0,1,1)x(0,1,1). Con il nuovo set di dati però, il modello migliore (figura 4.9) è risultato differente dal precedente: SARIMA(1,1,0)x(0,1,1) con un AIC pari a 1372, inferiore all'altro (=1376).

```
Call:
arima(x = dati, order = nsorder, seasonal = list(order = sorder, period = periodo),
    include.mean = vf)

Coefficients:
          ar1     sma1
      -0.3688  -1.0000
s.e.   0.0515   0.0497

sigma^2 estimated as 3.463:  log likelihood = -683.06,  aic = 1372.13

$tstatistics
       ar1       sma1
 -7.166207 -20.122473
```

Figura 4.9 output del modello SARIMA(1,1,0)x(0,1,1) sul dataset ristretto

In seguito, l'obiettivo dell'indagine è stato quello di verificare se l'esclusione degli outlier portasse a un miglioramento nella diagnostica dei residui, e i risultati hanno confermato le aspettative. Sebbene la normalità sia risultata meno evidente, ma comunque presente come mostrato in figura 4.10a, diverso è stato l'esito per quanto riguarda il correlogramma. Dopo le modifiche apportate alla serie storica, infatti, i residui sono risultati significativamente incorrelati (figura 4.10b).

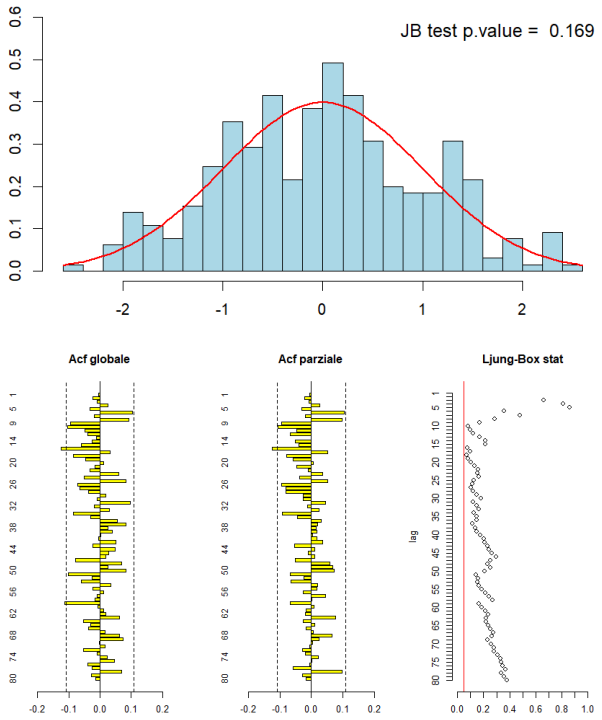

Figura 4.10a - 4.10b: diagnostica dei residui del SARIMA(0,1,1)x(0,1,1) sul dataset ristretto

Terminata la diagnostica, si può finalmente ritenere conclusa la quarta fase della procedura di Box-Jenkins, passando dunque alla quinta ed ultima: la previsione.

Per predire i valori futuri è stata adoperata nuovamente la funzione forecastplott, avente come input il modello scelto e che ha restituito i valori puntuali della serie previsti fino al 2050 (figura 4.11). Osservandoli, emerge chiaramente un trend crescente progressivo con un aumento annuo medio di 3-4 mm, che si traduce in un aumento totale di 90 mm dal 2025 al 2050. Come avvenuto per la serie della CO_2, anche in questo caso le previsioni seguono l'andamento della serie storica, presentando una stagionalità abbastanza evidente.

Inoltre, la funzione forecastplott consente di visualizzare graficamente le previsioni, inserendole all'interno di bande di confidenza (tramite linee tratteggiate) che delimitano la variabilità della serie nei periodi futuri. L'aumento dell'ampiezza di queste bande rispecchia l'aumento dell'incertezza associata a stime più lontane dall'orizzonte temporale di partenza.

Osservando la rappresentazione grafica nella figura 4.12 si osservano chiaramente il trend crescente e la componente stagionale citati in precedenza per le previsioni puntuali; inoltre è possibile osservare ulteriormente come il modello catturi e riproduca la struttura della serie.

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
2025			70.17196	68.59665	67.77863	68.90742	71.93744	75.28832	78.98086	80.07410	78.23197	75.92965
2026	74.09204	73.58450	73.51414	72.05956	71.19701	72.34222	75.36618	78.71929	82.41101	83.50456	81.66232	79.36004
2027	77.52240	77.01487	76.94451	75.48993	74.62738	75.77259	78.79655	82.14966	85.84138	86.93493	85.09269	82.79041
2028	80.95278	80.44525	80.37488	78.92030	78.05775	79.20296	82.22692	85.58003	89.27175	90.36530	88.52306	86.22078
2029	84.38315	83.87562	83.80525	82.35067	81.48812	82.63334	85.65729	89.01040	92.70213	93.79567	91.95343	89.65115
2030	87.81352	87.30599	87.23562	85.78104	84.91849	86.06371	89.08767	92.44078	96.13250	97.22604	95.38380	93.08152
2031	91.24389	90.73636	90.66600	89.21141	88.34886	89.49408	92.51804	95.87115	99.56287	100.65641	98.81417	96.51189
2032	94.67426	94.16673	94.09637	92.64179	91.77924	92.92445	95.94841	99.30152	102.99324	104.08679	102.24455	99.94227
2033	98.10463	97.59710	97.52674	96.07216	95.20961	96.35482	99.37878	102.73189	106.42361	107.51716	105.67492	103.37264
2034	101.53500	101.02747	100.95711	99.50253	98.63998	99.78519	102.80915	106.16226	109.85398	110.94753	109.10529	106.80301
2035	104.96538	104.45785	104.38748	102.93290	102.07035	103.21557	106.23952	109.59263	113.28436	114.37790	112.53566	110.23338
2036	108.39575	107.88822	107.81785	106.36327	105.50072	106.64594	109.66990	113.02301	116.71473	117.80827	115.96603	113.66375
2037	111.82612	111.31859	111.24823	109.79364	108.93109	110.07631	113.10027	116.45338	120.14510	121.23864	119.39640	117.09412
2038	115.25649	114.74896	114.67860	113.22402	112.36147	113.50668	116.53064	119.88375	123.57547	124.66902	122.82678	120.52450
2039	118.68686	118.17933	118.10897	116.65439	115.79184	116.93705	119.96101	123.31412	127.00584	128.09939	126.25715	123.95487
2040	122.11723	121.60970	121.53934	120.08476	119.22221	120.36742	123.39138	126.74449	130.43621	131.52976	129.68752	127.38524
2041	125.54761	125.04008	124.96971	123.51513	122.65258	123.79780	126.82175	130.17486	133.86659	134.96013	133.11789	130.81561
2042	128.97798	128.47045	128.40008	126.94550	126.08295	127.22817	130.25213	133.60524	137.29696	138.39050	136.54826	134.24598
2043	132.40835	131.90082	131.83045	130.37587	129.51332	130.65854	133.68250	137.03561	140.72733	141.82087	139.97863	137.67635
2044	135.83872	135.33119	135.26083	133.80624	132.94369	134.08891	137.11287	140.46598	144.15770	145.25125	143.40901	141.10672
2045	139.26909	138.76156	138.69120	137.23662	136.37407	137.51928	140.54324	143.89635	147.58807	148.68162	146.83938	144.53710
2046	142.69946	142.19193	142.12157	140.66699	139.80444	140.94965	143.97361	147.32672	151.01844	152.11199	150.26975	147.96747
2047	146.12984	145.62231	145.55194	144.09736	143.23481	144.38003	147.40398	150.75709	154.44882	155.54236	153.70012	151.39784
2048	149.56021	149.05268	148.98231	147.52773	146.66518	147.81040	150.83436	154.18747	157.87919	158.97273	157.13049	154.82821
2049	152.99058	152.48305	152.41268	150.95810	150.09555	151.24077	154.26473	157.61784	161.30956	162.40310	160.56086	158.25858
2050	156.42095	155.91342	155.84306	154.38847	153.52592	154.67114	157.69510	161.04821	164.73993	165.83348	163.99124	161.68895

Figura 4.11: previsioni puntuali del livello di GMSL mensile ottenute con SARIMA(1,1,0)x(0,1,1) dal 2025 al 2050

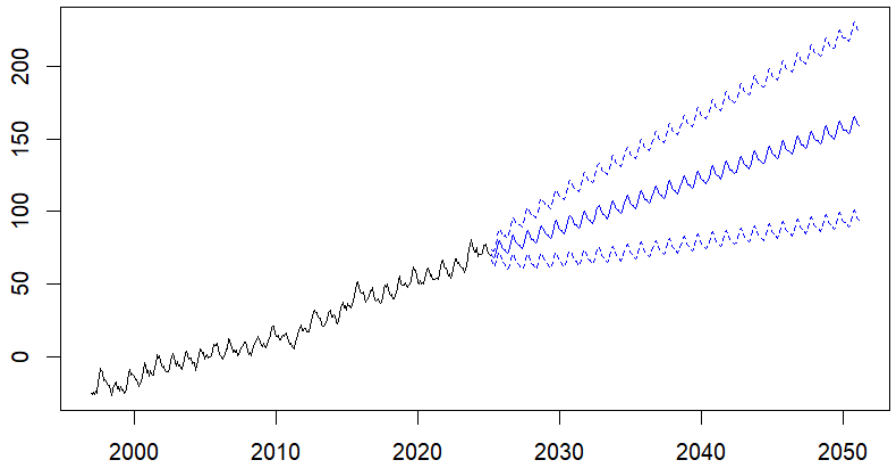

Figura 4.12: forecastplot del livello di GMSL mensile dal 2025 al 2050

4.4 Analisi Multivariata: Causalità e VAR

Per analizzare le dinamiche congiunte tra la concentrazione mensile di CO_2 e del GMSL all'interno di questa tesi è stato adottato come primo metodo il modello Vector AutoRegressive (VAR). Questo modello risulta particolarmente efficace nei contesti multivariati in cui si vogliono indagare effetti di interdipendenza e di causalità tra più serie temporali dal momento che, nella sua struttura, esso non solo tiene conto dei valori passati di ciascuna variabile, ma considera anche gli effetti dinamici esercitati tra variabili.

Un prerequisito fondamentale per l'utilizzo di un modello VAR è che le serie siano stazionarie (Zavanella, 2015). Per garantire ciò, le variabili analizzate in questo studio sono state

trasformate mediante differenza prima (lag 1) e differenza stagionale (lag 12), al fine di rimuovere trend e componenti stagionali.

Un elemento cruciale nella costruzione del modello VAR è la scelta del numero di lag k da includere nell'analisi e per farlo ci si è avvalsi della funzione VARselect() di Rstudio. Questo comando, appartenente alla libreria vars, stima un modello per ciascun ordine di ritardo. In seguito, basandosi sulla dimensione del campione, vengono calcolati criteri di selezione quali l'Akaike Information Criterion (AIC), lo Schwarz Criterion (SC/BIC) o l'Hannan Quinn Criterion (HQ). Questi criteri aiutano ad identificare l'ordine di ritardo che minimizza l'errore di previsione del modello e, nel caso dell'analisi di questo elaborato, si è scelto di utilizzare il k che minimizzasse l'AIC, criterio già utilizzato in precedenza nel corso di questo elaborato. Per questo motivo, il modello VAR applicato ha utilizzato k=3 e non ha incluso nessuna costante, configurazione indicata come ottimale dal criterio di scelta adottato.

Una volta definito il modello VAR(3), si è proceduto alla stima simultanea del sistema di due equazioni, in cui ciascuna variabile è trattata come endogena e spiegata dai propri lag e dai lag dell'altra variabile. Nell'equazione con variabile dipendente CO_2_monthly_avg, ad essere significativi sono solamente i coefficienti dei primi due lag della variabile stessa, mentre quelli della variabile gmsl_gia non risultano essere impattanti all'interno del modello. Al contrario nella seconda equazione, come mostrato nella figura 4.13, tra i lag della variabile dipendente gmsl_gia risulta significativo solamente il primo, sembra essere significativo anche il terzo lag della variabile indipendente, indicando un effetto ritardato ed un ritorno alla media del livello del mare.

```
Estimation results for equation d12_CO2:
========================================
d12_CO2 = d12_CO2.l1 + d12_GMSL.l1 + d12_CO2.l2 + d12_GMSL.l2 + d12_CO2.l3 + d12_GMSL.l3

             Estimate Std. Error t value Pr(>|t|)
d12_CO2.l1  -0.345969   0.052434  -6.598 1.47e-10 ***
d12_GMSL.l1  0.003254   0.008378   0.388   0.6980
d12_CO2.l2  -0.219353   0.054191  -4.048 6.32e-05 ***
d12_GMSL.l2 -0.009743   0.008891  -1.096   0.2739
d12_CO2.l3  -0.100534   0.052395  -1.919   0.0558 .
d12_GMSL.l3 -0.013431   0.008360  -1.607   0.1090
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1


Residual standard error: 0.445 on 364 degrees of freedom
Multiple R-Squared: 0.1243,     Adjusted R-squared: 0.1099
F-statistic: 8.612 on 6 and 364 DF,  p-value: 9.055e-09


Estimation results for equation d12_GMSL:
=========================================
d12_GMSL = d12_CO2.l1 + d12_GMSL.l1 + d12_CO2.l2 + d12_GMSL.l2 + d12_CO2.l3 + d12_GMSL.l3

             Estimate Std. Error t value Pr(>|t|)
d12_CO2.l1  -0.398211   0.325385  -1.224   0.2218
d12_GMSL.l1 -0.360979   0.051993  -6.943 1.77e-11 ***
d12_CO2.l2  -0.509691   0.336290  -1.516   0.1305
d12_GMSL.l2 -0.037064   0.055177  -0.672   0.5022
d12_CO2.l3  -0.827097   0.325143  -2.544   0.0114 *
d12_GMSL.l3 -0.006541   0.051877  -0.126   0.8997
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Figura 4.13: output della stima del modello VAR(3)

A questo punto, sebbene le performance del modello non fossero delle migliori, si è deciso di proseguire e di provare a vedere come questo si comportasse in termini di previsione. Tramite

la funzione predict() sono state effettuate le proiezioni dei valori mensili di CO_2 e del GMSL per un anno dall'ultimo valore registrato, come si può osservare nella figura 4.14.

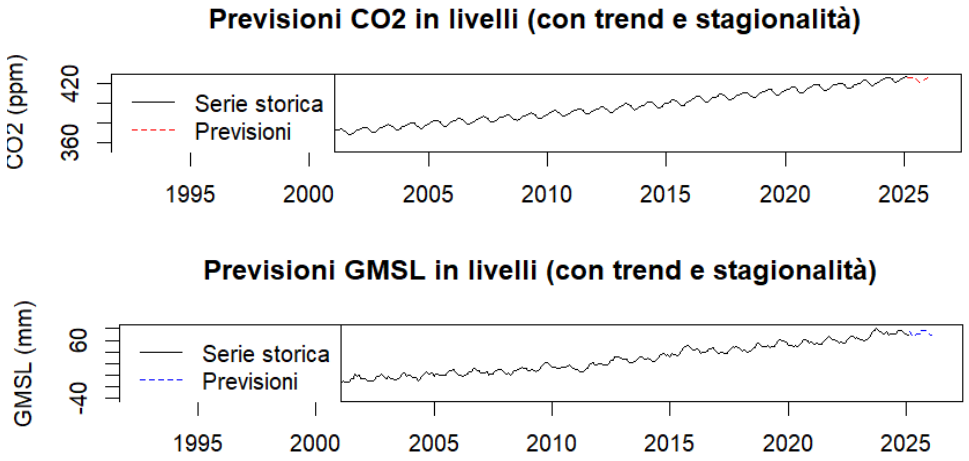

Figura 4.14: previsioni dei livelli di CO_2 e GMSL ottenute tramite VAR(3)

Dall'osservazione dei grafici delle serie e delle loro proiezioni emerge che il modello VAR, stimato sulle serie destagionalizzate e differenziate, riesce a cogliere bene la componente autoregressiva interna di entrambe le variabili: le variazioni passate di ciascuna serie influenzano chiaramente le rispettive variazioni future. Tuttavia, l'effetto di interazione tra le due variabili risulta complessivamente debole e poco marcato. Solo per il GMSL si nota un certo effetto ritardato delle variazioni di CO_2, mentre l'influenza inversa è trascurabile e statisticamente non significativa.

Questa limitata capacità del modello di rilevare relazioni incrociate significative suggerisce che il VAR, da solo, non basta a descrivere pienamente l'interazione dinamica tra le due serie storiche in questo contesto. Per approfondire il legame di precedenza temporale tra CO_2 e GMSL, viene quindi introdotto lo studio della causalità di Granger. Questo test permette di verificare se le variazioni passate di una variabile aiutano a migliorare la previsione dell'altra, andando oltre la semplice correlazione (Granger, 1969). In questo modo, si ottiene un quadro più chiaro delle relazioni causali e dinamiche tra le due serie.

Il test di causalità di Granger è stato applicato sulle serie stazionarie, destagionalizzate e differenziate, rispettando le condizioni necessarie per garantire la validità statistica. Inoltre è stato utilizzato un numero di lag k pari a 3, ovvero quelli scelti in precedenza nella stima del VAR tramite il criterio dell'Akaike. I risultati del test (figura 4.15a - 4.15b) indicano un'evidenza di causalità unidirezionale, seppur debole: le variazioni passate di CO_2 sembrano utili a migliorare la previsione delle variazioni del livello medio globale del mare (GMSL), ma solo al livello di confidenza del 10%, mentre l'effetto inverso non risulta significativo.

```
Granger causality test

Model 1: d12_co2_ts ~ Lags(d12_co2_ts, 1:3) + Lags(d12_gmsl_ts, 1:3)
Model 2: d12_co2_ts ~ Lags(d12_co2_ts, 1:3)
  Res.Df Df      F Pr(>F)
1    363
2    366 -3 1.1287 0.3373
```

```
Granger causality test

Model 1: d12_gmsl_ts ~ Lags(d12_gmsl_ts, 1:3) + Lags(d12_co2_ts, 1:3)
Model 2: d12_gmsl_ts ~ Lags(d12_gmsl_ts, 1:3)
  Res.Df Df      F  Pr(>F)
1    363
2    366 -3 2.4542 0.06295 .
```

Figure 4.15a - 4.15b: Risultato del test di causalità di Granger applicato in entrambi le direzioni

Questa evidenza moderata suggerisce che, pur esistendo un legame temporale tra le due variabili, il modello VAR basato solo sulle serie differenziate non riesce a catturare appieno le dinamiche di lungo periodo. Per questo motivo, risulta opportuno procedere nel prossimo paragrafo con un'analisi più approfondita tramite test di cointegrazione e, se necessario, tramite l'applicazione di modelli ECM.

4.5 Analisi Multivariata: Cointegrazione e ECM

Vista la relazione apparentemente debole tra le variazioni di CO_2 e il livello medio globale del mare, è necessario verificare l'esistenza di un legame stabile tra le due serie, per capire se esse tendano a muoversi insieme nel lungo periodo nonostante le fluttuazioni nel breve termine. Questa analisi sarà condotta tramite il test di Engle-Granger sulla cointegrazione (Engle & Granger, 1987), preferito al test di Johansen in quanto le serie in questione sono solamente due e quindi il test di Engle-Granger è un giusto trade off tra complessità e performance. In caso di evidenza positiva, verrà poi applicato un modello Error Correction Model (ECM), che migliora il VAR integrando sia la dinamica rapida delle variazioni sia la tendenza delle serie a tornare a un equilibrio comune.

Il test applicato si articola in due fasi: in primo luogo, si stima la relazione di lungo periodo tra le due serie tramite una regressione lineare ordinaria, ottenendo i residui della stima; successivamente, si verifica la stazionarietà di tali residui mediante un ADF test. La stazionarietà dei residui rappresenterebbe la prova che, pur essendo entrambe le serie integrate di ordine uno (I(1)), esse condividono un equilibrio di lungo periodo.

Nel caso della presente tesi, i residui sono risultati stazionari e ciò ha confermato la presenza di una relazione di cointegrazione, fornendo le basi per costruire un ECM (Lutkepohl, 2005). Per la costruzione di questo modello è stato in un primo momento costruito il termine di correzione dell'errore (ECT) a partire dai residui del modello costruito precedentemente che legava i livelli di gmsl a quelli di CO_2. In seguito sono state isolate le variazioni di breve periodo tramite le differenze prime delle serie, ed infine è stata stimata una regressione delle variazioni di gmsl sulle variazioni di CO_2 e sull'ECT, con l'aggiunta di un intercetta.

```
Call:
lm(formula = D_gmsl ~ D_co2 + ECT, data = ecm)

Residuals:
    Min      1Q  Median      3Q     Max 
-6.6112 -1.5191  0.0466  1.5089  5.7882 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  0.53865    0.11118   4.845 1.84e-06 ***
D_co2       -1.38743    0.08738 -15.879  < 2e-16 ***
ECT          0.07336    0.01472   4.984 9.48e-07 ***
```

Figura 4.16: output del modello ECM stimato

L'analisi dell'output dell'ECM (figura 4.16) mostra che sia le variazioni mensili di CO_2 sia il termine ECT risultano significativi ed il coefficiente della serie differenziata di CO_2 evidenzia che le variazioni immediate di diossido di carbonio influenzano il livello del mare nel breve periodo. Il coefficiente associato all'ECT, sebbene significativo, risulta relativamente piccolo (0.07), suggerendo che la correzione verso l'equilibrio di lungo periodo avviene in maniera graduale e moderata.

Per le previsioni tramite ECM, è stato necessario avere dei valori futuri per la variabile d_co2, trattata come indipendente in questo modello, e a riguardo sono stati utilizzati i valori di CO_2 predetti dal modello SARIMA stimato in precedenza (paragrafo 4.1). Il profilo delle proiezioni del GMSL (figura 4.17) risulta visibilmente più regolare rispetto alla serie storica: le oscillazioni di breve periodo, che caratterizzano i dati osservati del livello del mare, nelle previsioni ECM appaiono attenuate. Questo riflette il fatto che il modello, pur includendo la CO_2 differenziata per catturare gli effetti immediati, assegna un peso relativamente maggiore al termine di correzione dell'errore.

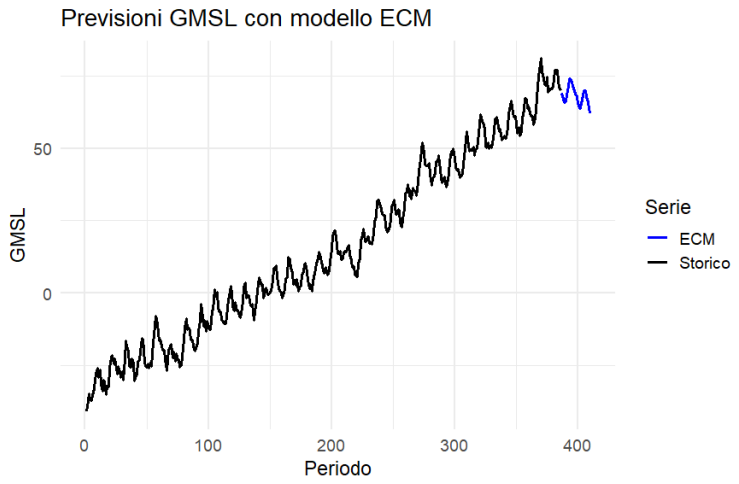

Figura 4.17: previsioni ottenute tramite il modello ECM

4.6 Analisi Multivariata: ARDL

A completamento dell'analisi dinamica tra CO_2 e il livello medio globale del mare (GMSL), è stato stimato un modello ARDL (AutoRegressive Distributed Lag) sui livelli delle due serie, un approccio che permette di stimare e prevedere i livelli di una serie basandosi sui livelli precedenti della serie stessa oltre che sui livelli passati di un'altra serie, considerata indipendente (Pesaran et al., 2001).

L'analisi dell'output (figura 4.18) mostra che i valori passati di GMSL esercitano un effetto positivo e significativo sul livello attuale, confermando la forte persistenza della serie osservata anche nei modelli VAR e ECM. Per quanto riguarda la CO_2, l'impatto sui livelli di GMSL risulta più complesso: i primi due lag dei livelli di CO_2 hanno un effetto negativo, mentre il lag a due mesi mostra un effetto positivo molto marcato e altamente significativo.

```
Time series regression with "ts" data:
Start = 1993(3), End = 2025(2)

Call:
dynlm(formula = gmsl_ts ~ L(gmsl_ts, 1:q) + L(co2_ts, 0:p))

Residuals:
    Min      1Q  Median      3Q     Max 
-5.9688 -1.4068 -0.1085  1.4716  5.2434 

Coefficients:
                  Estimate Std. Error t value Pr(>|t|)    
(Intercept)      -41.24738   10.71620  -3.849 0.000139 ***
L(gmsl_ts, 1:q)1   0.65130    0.04645  14.022  < 2e-16 ***
L(gmsl_ts, 1:q)2   0.27885    0.04763   5.854 1.04e-08 ***
L(co2_ts, 0:p)0   -0.63012    0.14343  -4.393 1.45e-05 ***
L(co2_ts, 0:p)1   -0.65533    0.25490  -2.571 0.010523 *  
L(co2_ts, 0:p)2    1.39626    0.14873   9.388  < 2e-16 ***
```

Figura 4.18: Output del modello ARDL stimato

Questo suggerisce la presenza di dinamiche ritardate tra la concentrazione di CO_2 e il livello del mare, che non erano pienamente catturate dai modelli precedenti basati su differenze.

Complessivamente, l'ARDL conferma l'influenza significativa, sebbene ritardata, dei livelli di CO2, offrendo un quadro più completo delle interazioni a breve e lungo termine rispetto a VAR ed ECM. Anche nel caso di questo modello, come già fatto in precedenza, si è proceduto dunque ad effettuare delle previsioni basandosi sul modello adottato, che determina il livello di gmsl sulla base dei lag di entrambi le variabili in questione.

Per la costruzione delle previsioni con l'ARDL è stato necessario disporre di valori futuri della CO_2, trattata come variabile esogena. Come già fatto nel caso del modello ECM, sono state quindi utilizzate le previsioni generate dal SARIMA presentato nel paragrafo 4.1, successivamente combinate con i valori osservati disponibili nel dataset. In questo modo è

stato possibile generare, per ciascun periodo futuro, i ritardi di primo e secondo ordine sia della CO_2 che del GMSL, indispensabili per l'applicazione del modello.

Le proiezioni ottenute (figura 4.19) mostrano un andamento più aderente al profilo della serie storica rispetto a quanto osservato per l'ECM: la dinamica stimata dall'ARDL tende a riprodurre più fedelmente la reale evoluzione dei livelli del mare, mantenendo un ritmo di crescita regolare e meno smorzato. Ciò riflette la natura del modello, che opera direttamente sui livelli delle variabili anziché sulle loro differenze, incorporando quindi in modo più diretto la memoria storica della serie. Infatti, anche estendendo la proiezione a 300 periodi futuri (pari a circa 25 anni), l'andamento rimane sostanzialmente invariato, con un trend crescente analogo a quello riportato in figura 4.19, dove l'orizzonte temporale considerato è limitato a soli 24 periodi (due anni).

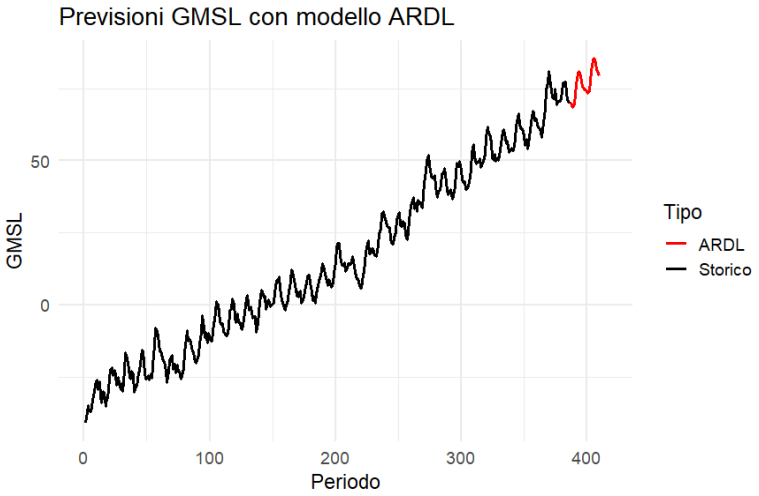

Figura 4.19: previsioni ottenute tramite il modello ARDL

4.7 Conclusione e discussione dei risultati

L'analisi univariata ha mostrato risultati soddisfacenti per entrambi le serie storiche: in entrambi i casi i modelli SARIMA selezionati sono stati in grado di catturare in maniera efficace sia la stagionalità sia la tendenza di lungo periodo di ciascuna delle due serie, restituendo per ognuna delle previsioni coerenti con l'andamento osservato.

L'analisi multivariata ha consentito di indagare la relazione tra concentrazione atmosferica di CO_2 e livello medio globale del mare (GMSL) attraverso tre approcci modellistici differenti:

- Il modello VAR(3), stimato sulle serie rese stazionarie tramite differenziazione, ha confermato la presenza di una forte componente autoregressiva interna a ciascuna variabile. Tuttavia, l'interazione tra CO_2 e GMSL è risultata debole e poco

significativa, limitando la capacità del modello di descrivere relazioni dinamiche tra le due serie. Il test di causalità di Granger ha confermato questa evidenza, mostrando soltanto una debole causalità unidirezionale da CO_2 verso GMSL.

- La verifica della cointegrazione ha invece evidenziato l'esistenza di un legame di lungo periodo, che ha reso possibile l'applicazione di un ECM. Questo modello ha mostrato come le variazioni immediate della CO_2 influenzino significativamente il livello del mare, mentre il termine di correzione dell'errore descrive un lento aggiustamento verso l'equilibrio comune. Le previsioni risultano coerenti con tale struttura, ma mostrano un andamento più regolare e smorzato rispetto ai dati osservati, con oscillazioni attenuate e una dinamica meno realistica.
- il modello ARDL, stimato sui livelli delle variabili, si è dimostrato il più efficace nell'interpretare le dinamiche congiunte. Le proiezioni ottenute sono risultate più aderenti al profilo storico della serie, mantenendo un trend crescente anche su orizzonti temporali estesi e senza l'eccessiva smorzatura osservata con l'ECM.

Nel complesso, il confronto tra i modelli mostra come ciascuno offra una prospettiva diversa: il VAR descrive bene le dinamiche interne ma non coglie pienamente le interazioni; l'ECM integra la componente di equilibrio di lungo periodo, ma con l'effetto di avere previsioni più smorzate; l'ARDL, infine, emerge come l'approccio più robusto e realistico, in grado di rappresentare sia gli effetti di breve che di lungo periodo e di fornire proiezioni maggiormente coerenti con l'andamento effettivo delle serie storiche.

Conclusione e sviluppi futuri

All'interno della presente tesi è stato affrontato un tema di straordinaria attualità e di estrema rilevanza all'interno del dibattito scientifico: il cambiamento climatico, le sue cause e le sue fatali conseguenze. Nello specifico è stata indagata la relazione tra le emissioni di CO_2 atmosferica e l'innalzamento del livello medio globale del mare. A partire da una rassegna della letteratura scientifica internazionale, che ha mostrato come nel corso degli ultimi decenni siano stati sviluppati numerosi approcci diversi tra loro, di natura sia empirica sia fisico-modellistica, si è scelto di adottare una prospettiva statistica fondata sull'analisi delle serie storiche.

Il percorso di ricerca sviluppato in questo elaborato si è articolato in più fasi. Dopo aver illustrato lo stato dell'arte relativo alla questione ambientale e le principali tecniche statistiche adottate, i dati sono stati sottoposti a un processo di pulizia e analisi esplorativa preliminare. Successivamente è stata applicata la procedura di Box-Jenkins per la modellizzazione univariata (tramite SARIMA). In un secondo momento, l'attenzione si è spostata su modelli multivariati, scelti per la loro capacità di cogliere e descrivere la relazione dinamica che lega le variabili oggetto di studio (VAR, ECM, ARDL).

I risultati ottenuti dalle analisi univariate e multivariate si sono rivelati tra loro coerenti e, proprio per questo, particolarmente significativi e al tempo stesso preoccupanti: essi confermano con chiarezza l'esistenza di un forte legame tra le emissioni di CO_2 e l'innalzamento del livello del mare, sottolineando l'urgenza del problema e la concretezza dei rischi. In particolare, lo studio univariato sul GMSL ha prodotto una previsione di crescita di circa 10 cm entro il 2050. Un aumento che non può essere considerato remoto o astratto, ma che riflette processi già in atto, con conseguenze tangibili come erosione costiera, inondazioni, intrusioni saline nelle falde acquifere e pressioni crescenti sugli ecosistemi e sulle comunità umane, soprattutto quelle più vulnerabili.

Nell'analisi multivariata, il modello ARDL si è distinto per la sua capacità di rappresentare in modo equilibrato sia le dinamiche di breve periodo sia quelle di lungo periodo, restituendo proiezioni in linea con i trend storici e meno soggette a distorsioni rispetto ad altri approcci. Questo risultato costituisce un valore aggiunto rispetto a gran parte della letteratura esistente, che tende spesso a concentrarsi su scenari di lungo termine basati su simulazioni fisiche complesse o su modelli puramente teorici. Al contrario, il lavoro svolto ha messo in evidenza

come strumenti statistici moderni e flessibili possano offrire un contributo rilevante, traducendo fenomeni di grande complessità in risultati quantitativi chiari e interpretabili..
Infine, per concludere questo lavoro, è opportuno volgere lo sguardo ai possibili orizzonti di ricerca ancora inesplorati, che potrebbero arricchire ed estendere i risultati fin qui conseguiti. A tal proposito, sono state individuate alcune direttrici di sviluppo promettenti.

- Una prima prospettiva consiste nell'ampliare l'insieme delle variabili considerate, includendo ad esempio la temperatura media globale o l'estensione dei ghiacciai, così da costruire modelli multivariati ancora più robusti e in grado di cogliere con maggiore precisione la complessità delle dinamiche climatiche.
- Un secondo possibile sviluppo riguarda l'adozione di modelli di serie storiche più complessi e non lineari, come le reti Long Short Term Memory (LSTM), capaci di individuare pattern latenti e relazioni difficilmente rilevabili con metodologie tradizionali.
- Un'ultima via percorribile potrebbe consistere nell'analisi a un livello geografico più disaggregato. L'innalzamento del mare, infatti, non si manifesta in modo uniforme a livello globale, ma presenta variazioni significative tra le diverse aree del pianeta. Introdurre la dimensione spaziale dello studio permetterebbe di ottenere risultati utili anche in termini applicativi, ad esempio per la pianificazione urbana, la gestione delle risorse naturali e la valutazione dei rischi costieri.

In definitiva, questa tesi ha mostrato come l'analisi statistica avanzata possa non solo contribuire a una migliore comprensione dei fenomeni legati al cambiamento climatico, ma anche rafforzare il dialogo tra discipline diverse, offrendo un ponte tra la ricerca empirica e la modellistica climatica tradizionale.

Bibliografia

Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control, 19(6)*, 716–723.

Box, G. E. P., & Jenkins, G. M. (1976). *Time series analysis: Forecasting and control*. Holden-Day.

Brockwell, P. J., & Davis, R. A. (2016). *Introduction to time series and forecasting*. Springer.

De Boor, C. (2001). *A practical guide to splines* (Rev. ed.). New York: Springer.

Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association, 74(366)*, 427–431.

Eckaus, R. S. (1994). Comparative analysis of alternative strategies for limiting greenhouse gas emissions. *Energy Journal,* 151–177.

Engle, R. F., & Granger, C. W. J. (1987). Cointegration and error correction: Representation, estimation, and testing. *Econometrica, 55(2)*, 251–276.

Ferron, F. A., Simoes, J. C., Aquino, F. E., & Setzer, A. W. (2004). Air temperature time series for King George Island, Antarctica. *Pesquisa Antártica Brasileira, 4(1)*, 155–169.

Foster, G. L., & Rohling, E. J. (2013). Relationship between sea level and climate forcing by CO_2 on geological timescales. *Proceedings of the National Academy of Sciences, 110(4)*, 1209–1214.

Frankenhuis, W. E., Nettle, D., & Dall, S. R. X. (2019). A case for environmental statistics of early life. *Proceedings of the Royal Society B: Biological Sciences, 286(1906)*, 20191628.

Grandey, B. S., Wong, T. E., Hermans, T. H. J., Kopp, R. E., & Garner, A. J. (2024). Fusion of probabilistic projections of sea-level rise. *Nature Communications, 15(1)*, 2601.

Hamilton, J. D. (1994). *Time series analysis*. Princeton University Press.

IPCC. (2014). *Climate Change 2014: Synthesis Report. Contribution of Working Groups I, II and III to the Fifth Assessment Report of the Intergovernmental Panel on Climate Change.* Geneva: IPCC.

IPCC. (2023). *Climate Change 2023: Synthesis Report. Contribution of Working Groups I, II and III to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change.* Geneva: IPCC.

Jarque, C. M., & Bera, A. K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters, 6(3)*, 255–259.

Johansen, S. (1988). Statistical analysis of cointegration vectors. *Journal of Economic Dynamics and Control, 12(2–3)*, 231–254.

Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika, 65(2)*, 297–303.

Lütkepohl, H. (2005). *New introduction to multiple time series analysis*. Springer.

Maddah, H. A. (2016). Modeling the relation between carbon dioxide emissions and sea level rise for the determination of future (2100) sea level. *American Journal of Environmental Engineering, 6(1)*, 1–7.

Mimura, N. (2013). Sea-level rise caused by climate change and its implications for society. *Proceedings of the Japan Academy, Series B, 89(7)*, 281–301.

Mudelsee, M. (2019). Trend analysis of climate time series: A review of methods. *Earth-Science Reviews, 190*, 310–333.

NASA. (consultata a Maggio 2025). Climate Change: Vital Signs of the Planet – Carbon Dioxide. Disponibile su: https://climate.nasa.gov/vital-signs/carbon-dioxide/?intent=121

NASA. (consultata a Maggio 2025). Climate Change: Vital Signs of the Planet – Sea Level. Disponibile su: https://climate.nasa.gov/vital-signs/sea-level/?intent=121

Pesaran, M. H., Shin, Y., & Smith, R. J. (2001). Bounds testing approaches to the analysis of level relationships. *Journal of Applied Econometrics, 16(3)*, 289–326.

Rahmstorf, S. (2007). A semi-empirical approach to projecting future sea-level rise. *Science, 315(5810)*, 368–370.

Ramaswamy, V., et al. (2001). Radiative forcing of climate change. In J. T. Houghton, Y. Ding, D. J. Griggs, M. Noguer, P. J. van der Linden, & D. Xiaosu (Eds.), *Climate Change 2001: The Scientific Basis. Contribution of Working Group I to the Third Assessment Report of the Intergovernmental Panel on Climate Change* (pp. 349–416). Cambridge University Press.

Revelle, R. (1982). Carbon Dioxide and World Climate. *Scientific American, 247(2)*, 31–39.

Riebeek, H. (2011). *The Carbon Cycle*. NASA Earth Observatory.

Schmalensee, R., Stoker, T. M., & Judson, R. A. (1998). World carbon dioxide emissions: 1950–2050. *Review of Economics and Statistics, 80(1)*, 15–27.

Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics, 6(2)*, 461–464.

United Nations (1998). Kyoto Protocol to the United Nations Framework Convention on Climate Change. *UN Treaty Series, 2303*, p. 162.

United Nations (2015). *Paris Agreement*. United Nations Treaty Collection.

Wei, W. W. S. (2006). *Time series analysis: Univariate and multivariate methods* (2nd ed.). Pearson Addison Wesley.

Wold, H. (1938). *A study in the analysis of stationary time series.* Stockholm: Almqvist & Wiksell.

Zavanella, L. (2005). *Modelli e metodi per l'analisi delle serie storiche*. Carocci Editore